

PrivAI L'illusion de l'Ølecteur synthØtique et la sou

Pourquoi l'AI Safety doit protØger le dØmos contre les
personnes morales augmentØes

CADRE EDITORIAL & PROVENANCE

Direction editoriale : Jean Hugues No¶ Robert, baron Mariani

Editeur responsable : Institut Mariani / C.O.R.S.I.C.A.

Date de projection : 2026-10-05 | Langue : fr

Licence : Creative Commons CC BY-SA 4.0 (Open Commons Default)

STATUT : PROJECTION EN PREPARATION NON GELEE

Ce document constitue le tirage d'epreuve du manuscrit courant.

Il ne vaut pas edition gelee ni certification.

SOMMAIRE DU MANUSCRIT

Chapitre 1 : PrivAI n°1 Qui restera souverain ?

Chapitre 2 : PrivAI n°1 Chapitre 1 : Le mauvais scénario de science-fiction

Pourquoi le péril politique de l'IA ne commence pas par une machine qui se révolte

Chapitre 3 : PrivAI n°1 Chapitre 2 : L'asymétrie est déjà là

Mémoire, données, capital, procédures, temps, juristes, compute et agents

Chapitre 4 : PrivAI n°1 Chapitre 3 : La personne morale augmentée

De l'assistance à l'autonomisation fonctionnelle

Chapitre 5 : PrivAI n°1 Chapitre 4 : Liberté formelle, capacité réelle

L'Autonomie de Capacité appliquée à l'IA

Chapitre 6 : PrivAI n°1 Chapitre 5 : La pathologie du secret

Quand l'algorithme dilue mandat, responsabilité et imputabilité

Chapitre 7 : PrivAI n°1 Chapitre 6 : Prouver face à une machine institutionnelle

Traces, chronologie, conservation, provenance et reconstruction

Chapitre 8 : PrivAI n°1 Chapitre 7 : Le jumeau numérique souverain

Mémoire et continuité au service de la personne, non à sa place

Chapitre 9 : PrivAI n°1 Chapitre 8 : KYS : qui a le droit de me représenter ?

Consentement, correction, révocation et usages autorisés

Chapitre 10 : PrivAI n°1 Chapitre 9 : Democratic Humans in the Loop

L'humain doit garder une capacité réelle, pas une présence cérémonielle

Chapitre 11 : PrivAI n°1 Chapitre 10 : L'infrastructure est l'AI Safety

Compute, données, énergie, modèles et dépendances

Chapitre 12 : PrivAI n°1 Chapitre 11 : Des individus capables ensemble

Articulation avec les communs cognitifs sans capture collective

Chapitre 13 : PrivAI n°1 Chapitre 12 : PrivAI comme Reality Test

Mesurer les capacités réellement rendues à la personne

PrivAI n°1 Qui restera souverain ?

PrivAI n°1 Qui restera souverain ?

****AI Safety, personnes morales augmentées et contre-pouvoir cognitif humain****

Projection de lecture du 4 octobre 2026. Ce n'est pas une édition gelée, pas une charte nouvelle, et pas une certification.

Si cette page et 'projects/privai/site/n1.html' divergent, le présent fichier est la source de corpus.

Deux questions déjà écrites

Le paquet de reprise de ce Livre pose :

> ****Qui restera souverain à l'âge des personnes morales augmentées par l'IA ?****

Le dépôt [acorsica/privai](https://github.com/acorsica/privai), au commit 'f7fe0c03e718bef1deb6c6f8beb2b3af84e39e55', pose une question opérationnelle déjà publiée :

> ****Qui peut agir, au nom de qui, dans quelles limites, et avec quelles preuves ?****

La première vient de *Democratic AI Safety* et du plan de n°1. La seconde vient de l'initiative PrivAI telle qu'elle existe. Le Livre les tient ensemble. Il ne remplace pas la charte, les profils KYS, les contrats ni les configurations de conformance de ce dépôt.

Quatre niveaux à ne pas confondre

“text IA dangereuse en soi ‘ usage dangereux de l'IA ‘ asymétrie institutionnelle amplifiée par l'IA ‘ perte de souveraineté humaine “

Democratic AI Safety traite les deux derniers niveaux sans nier les deux premiers. Le claim C1 y est une thèse analytique, pas un fait mesuré : les cadres d'AI Safety centrés sur le modèle sont nécessaires et insuffisants s'ils ignorent l'agence politique des institutions augmentées. Le falsificateur nommé est une revue montrant que ces cadres empêchent déjà de façon exécutoire, la capture de la décision démocratique.

Traçabilité des actes, §8, formule le risque opératoire : une personne morale déjà puissante, augmentée par des systèmes d'IA, dont la chaîne d'imputabilité reste peu visible. Ce n'est pas la thèse qu'une machine se révolte.

Sommaire relié

1. Le mauvais scénario de science-fiction

La question du n°1 ne commence pas par une IA qui prendrait le pouvoir seule. Elle commence par des acteurs qui existent déjà: sociétés, fondations, fonds,

associations, administrations, plateformes. C2 dans *Democratic AI Safety* rappelle qu'une personne morale peut déjà posséder, contracter, plaider, influencer et durer. L'IA s'ajoute à cette capacité. Elle n'en est pas la condition d'existence.

2. L'asymétrie est déjà là

Mémoire, données, capital, procédures, temps, juristes, calcul et agents ne sont pas répartis comme les droits formels. Le §8 de *Traçabilité des actes* liste des augmentations déjà descriptibles : veille, rédaction, argumentaires, simulation, réponses institutionnelles, optimisation, ciblage, justification a posteriori, lobbying assisté. Ce sont des capacités possibles, pas une mesure unique de puissance.

3. La personne morale augmentée

C3 est une hypothèse : l'IA peut augmenter la capacité politique des personnes morales. Le falsificateur nommé est une évidence empirique que l'IA décentralise d'abord le pouvoir vers les personnes physiques et n'augmente pas sensiblement l'influence des personnes morales déjà puissantes. Le n°1 n'a pas encore ce test.

4. Liberté formelle, capacité réelle

La grammaire d'Autonomie de Capacité dit qu'elle n'est pas un catalogue de mesures, mais une méthode pour produire des mesures capables. L'appliquer à l'IA est un geste de ce Livre. Ce geste n'est pas un résultat déjà démontré dans 'research/autonomia/grammaire_autonomie_de_capacite.md'.

C4, dans *Democratic AI Safety*, est l'hypothèse correspondante : des humains peuvent rester formellement électeurs tout en devenant moins effectifs si des personnes morales augmentées dominent le droit, les marchés, l'attention et la croyance publique.

5. La pathologie du secret

La thèse de *La pathologie du secret* est :

> On ne peut pas exiger un humain pour posséder, puis accepter une machine pour gouverner.

Le secret tactique peut être légitime. L'opacité structurelle est autre chose : elle protège souvent ceux qui administrent le système. DataJust y est un cas documentaire du droit français, pas une preuve générale que tout algorithme public est illégitime.

6. Prouver face à une machine institutionnelle

Une trace utile répond : quel acte, par qui ou par quel système, au nom de quel mandat, avec quelle justification, avec quels effets, qui en répond, comment contester, corriger ou révoquer.

La chaîne minimale du même document est : trace, imputation, justification, correction, révocation ou sanction.

Quatre dilutions sont nommées : « l'institution a décidé », « le processus a été suivi », « le système l'a proposé », « le modèle l'a recommandé ».

Une trace négative enregistre une absence de suite. Elle ne convertit pas le silence en intention. Tracer l'anomalie n'est pas expliquer sa cause.

7. Le jumeau numérique souverain

L'initiative PrivAI préfigure une agence numérique portable : garder la maîtrise des traces, des représentations, des mandats et des actes au changement de modèle, d'opérateur ou d'infrastructure. Un jumeau peut assister. La charte dit qu'il ne vote pas à la place de la personne, n'exerce pas un mandat à sa place, et ne rend pas l'imputation impossible.

Cette projection ne décrit pas un produit livré.

8. KYS : qui a le droit de me représenter ?

La note KYS du 13 août 2026 pose une règle compacte : la personne décide ce qui est partagé, et ce qui peut être fait de ce partage. Le mécanisme proposé est un profil spécialisé, borné par une finalité. Le Cogentigram structurel n'y est pas une mémoire épisodique, pas un diagnostic, et pas une preuve judiciaire. La note dit elle-même que ces profils publics sont des prototypes, pas le produit PrivAI final.

9. Democratic Humans in the Loop

DHITL étend l'humain dans la boucle du geste technique vers une condition politique : la gouvernance de l'infrastructure de calcul. *Democratic AI Safety*, C7, ajoute qu'un opérateur économiquement subordonné ne suffit pas. Le §11.5 du même texte laisse une tension explicite : « all you need » se lit comme le niveau infrastructure, la gouvernance démocratique restant un niveau au-dessus. Le n°1 ne tranche pas cette tension.

10. L'infrastructure est l'AI Safety

Le calcul, les données, l'énergie, les modèles et les dépendances conditionnent les droits qui restent exerçables. Solid, tel que le README de l'initiative le distingue, porte d'abord sur le lieu des données et l'accès. PrivAI, dans ce même README, porte sur l'usage, la délégation d'agir et l'imputabilité. Les deux sont présents comme complémentaires. PrivAI n'y dépend d'aucun stockage particulier.

11. Des individus capables ensemble

Le Livre Vivant prévoit une confédération : renforcer, ne pas cloner. C.O.R.S.I.C.A. peut fournir une infrastructure commune sans devenir l'éditeur de chaque Livre. L'objection 7 de *Democratic AI Safety* reste ouverte : un commun peut lui aussi être capturé. La capacité collective n'est pas, par elle-même, une souveraineté personnelle.

12. PrivAI comme Reality Test

La question pratique d'ajout dans l'architecture de ce projet est :

> Après intervention de PrivAI, la personne dispose-t-elle réellement de davantage de capacité autonome, vérifiable et révocable qu'avant ?

Cette question s'articule désormais autour du cadre méthodologique du **Capable Test** et des **sept Reality Cases** empiriques documentés dans le dossier 'cases' (le jumeau test en migration [Case 01], le précédent DataJust [Case 02], la traçabilité contre les dilutions décisionnelles [Case 03], le profilage cognitif borné KYS [Case 04], la boîte noire Parcoursup [Case 05], la présomption de fiabilité machine Horizon [Case 06], et l'automatisation du soupçon Robodebt [Case 07]). L'épreuve fondatrice de démonstration reste l'export puis l'import de Twin sous air-gap avec modèles ouverts, garantissant la conservation vérifiable du principal, des mandats, de la mémoire source, des traces et de la reprise.

Statut institutionnel retenu

Formulation étroite, suffisante pour publier cette projection :

PrivAI est une initiative en développement dans le périmètre de l'Institut Mariani et de l'association C.O.R.S.I.C.A. Les liens documentaires avec les autres dépôts ne valent ni fusion, ni transfert de données, ni portage juridique, ni financement, ni endossement politique. PrivAI n'est pas un parti, une campagne, un outil électoral, ni une activité commerciale exploitée par C.O.R.S.I.C.A.

Une note de travail du 4 octobre 2026 dans ce dossier propose, en plus, une future PrivAI Foundation sans personnalité juridique propre, qui serait portée juridiquement par C.O.R.S.I.C.A. Les statuts n'ont pas été relus. Cette phrase n'est pas reprise comme un fait par la présente projection. Le détail est dans 'projects/privai/institutional-status.md'.

Ce que cette projection ne fait pas

- elle ne certifie aucun système, aucun modèle, aucune organisation ; - elle ne crée pas de personnalité juridique ; - elle ne branche pas le Guide public ; - elle ne déploie pas 'privai.acorsica.org' ; - elle ne recopie pas la charte PrivAI ; - elle ne traite pas les travaux voisins comme des concurrents.

Contredire

Une objection utile nomme le passage, la source, et le fait ou le texte qui le met en défaut. Le chemin est 'projects/privai/site/contribuer.html', ou l'issue [n°107](<https://github.com/JeanHuguesRobert/barons-Mariani/issues/107>).

PrivAI n°1 Chapitre 1 : Le mauvais scénario de science-fiction

Pourquoi le péril politique de l'IA ne commence pas par une machine qui se révolte

Chapitre 1 : Le mauvais scénario de science-fiction

1. L'aveuglement hollywoodien

Dans l'imaginaire contemporain, le danger ultime de l'intelligence artificielle est presque toujours mis en scène sous la forme d'une rupture spectaculaire : une machine ou un réseau qui s'éveille soudain à la conscience, refuse d'obéir à ses créateurs, s'empare des silos de missiles ou des réseaux électriques, et engage une guerre d'extermination ou de soumission contre l'humanité. De **Terminator** à **Matrix**, en passant par les variantes modernes de la singularité technologique ou de l'alignement superintelligent hors de contrôle, ce récit d'une « révolte des machines » sature le débat public.

Cette dramaturgie commode a un coût intellectuel et politique exorbitant : elle rend invisibles les menaces réelles, déjà à l'œuvre dans nos institutions.

En polarisant l'attention sur l'hypothèse lointaine d'une entité artificielle dotée d'une volonté propre et se rebellant contre l'ordre humain, la communauté de la sécurité de l'IA (**AI Safety**) dominante a souvent négligé un canal de capture bien plus immédiat, juridiquement armé et déjà historiquement enraciné : ****l'amplification disproportionnée des personnes morales existantes par l'intelligence artificielle****.

La question politique fondatrice n'est pas : ***« Que ferons-nous le jour où une machine exigera sa liberté ? »*** Elle est : ****« Qui restera souverain à l'âge des personnes morales augmentées par l'IA ? »****

2. Quatre niveaux à ne jamais confondre

Pour sortir du brouillard prospectif, il est indispensable d'ordonner la réalité selon une échelle de gravité et de nature distinctes. L'analyse de sécurité démocratique développée dans le Corpus (**Democratic AI Safety**, §1) pose quatre niveaux qu'il est impératif de ne jamais confondre :

“text Niveau 1 : L'IA dangereuse en soi ‘ Niveau 2 : L'usage dangereux de l'IA par un acteur malveillant ‘ Niveau 3 : L'asymétrie institutionnelle amplifiée par l'IA ‘ Niveau 4 : La perte effective de souveraineté humaine “

1. ****L'IA dangereuse en soi (Niveau 1)**** relève des failles intrinsèques du modèle : hallucinations critiques, biais toxiques, dérives d'alignement ou incapacité à maîtriser un processus de raisonnement récursif. C'est le terrain de l'*AI Safety* purement technique.
2. ****L'usage dangereux (Niveau 2)**** relève de la cybercriminalité, de la guerre de l'information ou du terrorisme assisté : un attaquant humain instrumentalise un outil algorithmique pour fabriquer des armes biologiques, perpétrer une fraude massive ou paralyser un hôpital.
3. ****L'asymétrie institutionnelle amplifiée (Niveau 3)**** change de nature : il ne

s'agit plus d'une infraction ni d'un bogue, mais du fonctionnement *légale et ordinaire* de structures de pouvoir (multinationales, banques d'investissement, administrations centrales, plateformes de données) qui intègrent des capacités d'optimisation, de mémoire, de veille, d'influence et de calcul hors de portée de toute personne physique. 4. **La perte de souveraineté humaine (Niveau 4)** constitue le point de bascule politique : la situation où les citoyens, tout en conservant formellement leurs droits constitutionnels et leur bulletin de vote, cessent d'être les véritables sujets de la décision collective, parce que l'environnement légal, discursif, économique et cognitif est intégralement préempté par des organisations machiniques.

PrivAI ne nie nullement la réalité des niveaux 1 et 2. Mais le projet pose avec force que l'AI Safety classique s'arrête exactement là où le danger politique commence : aux niveaux 3 et 4.

3. Le précédent séculaire : la corporation comme automate juridique

L'erreur originelle consiste à croire que les systèmes non-humains sont apparus avec le silicium. Or, la civilisation occidentale a inventé l'acteur non-humain doté d'immortalité et d'accumulation de puissance dès le Moyen Âge : **la personne morale** (*persona ficta*).

Comme l'ont formalisé les canonistes du XIII^e siècle (notamment le pape Innocent IV lors du concile de Lyon en 1245), puis le droit des sociétés commerciales à partir des Compagnies des Indes au XVII^e siècle, la personne morale est un artefact institutionnel capable : - de posséder des biens sans jamais mourir ; - d'ester en justice et de mobiliser des armées d'avocats ; - de contracter avec des tiers et d'échapper à la finitude biologique de ses fondateurs ; - d'accumuler du capital génération après génération ; - de diluer la responsabilité personnelle et morale individuelle derrière l'écran de l'intérêt social.

La corporation moderne fonctionnait déjà comme un algorithme institutionnel avant l'informatique : un ensemble de règles, de statuts, d'optimisations fiscales, de procédures hiérarchiques et de mandats visant à maximiser un objectif défini (le profit des actionnaires ou la perpétuation de l'appareil administratif). Dès le début du XX^e siècle, Max Weber décrivait la bureaucratie moderne comme une machinerie sociale fondée sur la calculabilité impersonnelle, observant que sa perfection technique s'accroît à mesure qu'elle se « déshumanise », c'est-à-dire qu'elle élimine de la gestion des affaires publiques les sentiments, l'empathie et les considérations personnelles insoumises au calcul formel.

L'introduction de l'intelligence artificielle ne crée pas ce pouvoir institutionnel autonome ex nihilo : **elle lui donne des ailes algorithmiques**.

L'IA confère à la personne morale une vitesse de calcul, une capacité de surveillance, une mémoire documentaire infinie et une réactivité tactique qui achèvent d'écraser l'échelle humaine. Ce que Weber qualifiait de « cage d'acier » de la rationalité instrumentale n'est plus seulement codifié dans des classeurs administratifs : il s'exécute désormais à la milliseconde, dans le langage naturel des grands modèles de fondation, simulant la conversation humaine pour mieux imposer des arbitrages automatisés.

4. De la Compagnie des Indes au scandale Horizon : la machine contre la chair

Ce processus n'a rien de virtuel. L'histoire récente regorge d'exemples tragiques où la personne morale, armée d'un automate logiciel défaillant, a préféré broyer méthodiquement des centaines d'êtres humains plutôt que d'admettre la faillibilité de ses systèmes.

L'archétype mondial de cette dérive est le ****scandale du Post Office britannique et du logiciel Horizon**** (documenté dans le ***Reality Case 06*** de PrivAI). Entre 1999 et 2015, plus de neuf cents sous-postiers de village ont été condamnés au pénal, ruinés ou emprisonnés pour de prétendus déficits de caisse qui n'étaient que des bugs informatiques et des corruptions de base de données. Face aux gérants désespérés jurant qu'ils n'avaient rien volé, l'institution a répété pendant quinze ans la même formule mécanique : ***« Le système informatique ne peut pas se tromper ; vous êtes le seul »***.

Dans cette tragédie institutionnelle, nul besoin d'une IA devenue consciente : une personne morale poursuivant sa propre préservation financière, adossée à la présomption juridique d'infailibilité de l'ordinateur et à des armées d'avocats procéduriers, a suffi pour suspendre l'état de droit pour des centaines de citoyens innocents.

Le danger n'est donc pas une créature cybernétique échappée d'un laboratoire de science-fiction ; le danger est la consolidation d'un féodalisme institutionnel où des personnes morales surpuissantes transforment les êtres humains en simples variables d'ajustement de leurs modèles prédictifs. La vraie AI Safety commence par la protection des personnes physiques contre cette domination machinale.

PrivAI n°1 Chapitre 2 : L'asymétrie est déjà là

Mémoire, données, capital, procédures, temps, juristes, compute et agents

Chapitre 2 : L'asymétrie est déjà là

1. La fiction de l'égalité formelle des parties

Le droit libéral classique repose sur un postulat philosophique majestueux mais aveugle : l'égalité théorique des sujets de droit devant la loi et le juge. Qu'il s'agisse d'un individu isolé ou d'une firme multinationale cotée, le code civil et le code de procédure les traitent comme des parties interchangeables, présumées également capables de contracter, de défendre leurs intérêts, de lire les clauses contractuelles et de produire des preuves.

Dans le monde matériel, cette égalité formelle a toujours été battue en brèche par les disparités économiques. Mais l'avènement de l'IA transforme cette disparité quantitative en une **rupture qualitative d'échelle cognitive**.

Un être humain est biologiquement borné : - sa mémoire de travail est limitée à quelques concepts simultanés ; - son temps de veille utile ne dépasse pas une quinzaine d'heures par jour ; - son énergie cognitive s'épuise face au jargon administratif, aux formulaires kafkaïens et aux procédures contentieuses dilatoires ; - sa durée de vie est finie et ses ressources financières s'érodent rapidement lors d'un litige.

Face à lui, la personne morale augmente opère sur un plan d'existence radicalement différent : - **Mémoire sans oublier** : indexation vectorielle exhaustive de millions de pages contractuelles, d'historiques d'échanges, de traces numériques et de précédents jurisprudentiels ; - **Présence continue** : surveillance algorithmique 24 heures sur 24, analyse en continu des comportements, réévaluation automatique des risques et des prix ; - **Puissance de calcul monopolistique** : clusters de serveurs capables de simuler des millions d'arbres de décision stratégiques en quelques secondes ; - **Endurance procédurale infinie** : capacité à multiplier les requêtes, à automatiser la rédaction d'écritures juridiques et à submerger l'adversaire sous des torrents de pièces sans jamais éprouver la moindre lassitude psychologique.

2. Les huit vecteurs de disproportion

L'analyse comparative formalisée dans l'annexe méthodologique de PrivAI (*Matrice des asymétries*, 2026) décompose ce gouffre structurel selon huit dimensions concrètes :

| Dimension | Personne physique (humain) | Personne morale augmentée (firme, plateforme, État) | |---|---|---| | ****1. Calcul & Infra**** | Terminaux personnels grand public, dépendants du cloud propriétaire. | Clusters industriels dédiés, modèles frontières en local, souveraineté matérielle. | | ****2. Mémoire & Contexte**** | Mémoire biologique sélective, perte d'archives, surcharge informationnelle. | RAG institutionnel massif, bases vectorielles illimitées,

historique exhaustif. | | **3. Temps & P rennit ** | Finitude biologique,  puisement psychique, temps contraint. | Immortalit  juridique, rotation impersonnelle des  quipes, endurance illimit e. | | **4. Vitesse d'ex cution** | Rythme circadien, d lib ration lente, d lais humains de lecture. | Inf rence   la milliseconde, automatisation des actes, d cision temps r el. | | **5. Pr sence active** | Attention morcel e, indisponibilit  fr quente. | Omnipr sence continue sur tous les canaux, capteurs et march s. | | **6. Capture cognitive** | Sujet aux biais de confirmation,   la fatigue et au profilage cibl . | Mod les pr dictifs de captation de l'attention, ing nierie comportementale de masse. | | **7. Imputabilit ** | Responsabilit  p onale et civile corporelle, non d l guable. | Dilution algorithmique des fautes, secret des affaires,  crans proc duraux. | | **8. Souverainet  effective** | Droits formels sur papier, impuissance pratique d'audit ou de riposte. | Capacit  unilat rale d'imposer des conditions d'usage et des arbitrages forc s. |

3. L'arsenal invisible de l'augmentation institutionnelle

Comme le rel ve le  8 du document source *Tra abilit  des actes*, l'augmentation par l'IA ne consiste pas   remplacer le pr sident-directeur g n ral par un algorithme. Elle consiste    quiper chaque  tage de la bureaucratie priv e ou publique d'un arsenal d'outils asym triques :

1. **La veille r glementaire pr dictive** : D tection pr coce des failles juridiques et des projets de loi avant m me leur d bat public, permettant de verrouiller des positions de lobbying avant que la soci t  civile n'ait compris l'enjeu. 2. **La r daction contentieuse de saturation** : G n ration industrielle de m moires en d fense de mille pages con us pour d courager les requ rants individuels et  puiser les magistrats instructeurs. 3. **Le profilage comportemental et la tarification discriminatoire** :  valuation dynamique de la vuln rabilit  psychologique ou financi re d'un citoyen ou consommateur, conduisant   des refus de pr t, des augmentations de prime d'assurance ou des censures de compte sans recours effectif. 4. **L'alibi algorithmique** : D fausse syst matique des dirigeants sur un pr tendu « mod le objectif » pour justifier des d cisions antisociales ou arbitraires (*« Ce n'est pas nous qui refusons votre droit, c'est l'algorithme de conformit  »*).

4. De Robodebt   la CAF : l'inversion unilat rale de la charge de la preuve

L'asym trie n'est pas une projection pour 2040. Elle est d j   v cue au quotidien par des millions de personnes vuln rables.

L' preuve la plus saisissante est celle du **scandale Robodebt en Australie** (document  dans le *Reality Case 07* de PrivAI). Pour traquer de suppos s indus chez les allocataires sociaux, l' tat f d ral a remplac  les contr leurs humains par un algorithme extrapolant m caniquement un revenu moyen sur l'ann e. En quelques clics, quatre cent mille dettes fictives ont  t  g n r es automatiquement, pour un montant de 1,7 milliard de dollars.

Ce n' tait pas seulement une erreur de calcul : c' tait une **inversion

unilatérale de la charge de la preuve**. L'État somme le citoyen précaire de prouver, sous vingt et un jours, qu'il ne devait rien à l'ordinateur, en exigeant des fiches de paie vieilles de sept ans. Face à une machine infatigable adossée à la force publique et à des agences privées de recouvrement agressif, des milliers de personnes ont payé des sommes qu'elles ne devaient pas, et plusieurs se sont donné la mort. Il a fallu une décision retentissante de la Cour fédérale en 2019 et une Commission royale d'enquête pour faire reconnaître la cruauté d'un système qui avait éliminé tout humain responsable de la boucle de décision.

Le même mécanisme de profilage prédictif aveugle a été condamné aux Pays-Bas dans l'affaire **SyRI** (*System Risk Indication*, 2020), où le tribunal de La Haye a annulé un algorithme de détection des fraudes ciblant de manière discriminatoire les quartiers défavorisés, au nom de l'article 8 de la Convention européenne des droits de l'homme.

Réduire cette tragédie à une simple « fracture numérique » relève de l'aveuglement idéologique. Il ne s'agit pas d'apprendre au citoyen à « cliquer sur le bon bouton » : il s'agit d'un **différentiel de puissance brute**. Face à une institution dotée de supercalculateurs, de juristes rompus à l'usage procédurale et d'algorithmes opaques, l'individu nu est condamné à plier, tant qu'il ne dispose pas de son propre bouclier cognitif capable de documenter l'erreur, d'exiger la trace et de porter la contradiction à égalité d'armes.

PrivAI n°1 Chapitre 3 : La personne morale augmentée

De l'assistance à l'autonomisation fonctionnelle

Chapitre 3 : La personne morale augmentée

1. La bascule : de l'outil passif à l'agent exécutif

Pendant des décennies, l'informatique de gestion est restée un outil subordonné. Une feuille de calcul, un progiciel de facturation ou un moteur de recherche documentaire exécutaient docilement des ordres humains délimités. L'employé lisait le résultat, prenait sa décision, signait le bordereau et engageait sa responsabilité ou celle de son service.

L'irruption des architectures d'agents autonomes et des modèles de fondation opère une rupture paradigmatique : le passage de **"l'assistance bureautique"** à **"l'autonomisation fonctionnelle"**.

Dans une personne morale moderne, les systèmes d'IA ne se contentent plus de suggérer une formulation ou de classer un dossier : - ils détectent des signaux faibles de marché à la microseconde ; - ils orchestrent des chaînes d'actions complexes reliant bases de données, API bancaires et envois de courriers recommandés électroniques ; - ils déclenchent de manière autonome des suspensions de service, des pénalités financières, des clôtures de compte ou des licenciements algorithmiques (comme l'illustrent les plateformes de livraison ou de logistique) ; - ils produisent des justifications narratives rétrospectives parfaites, calibrées pour décourager tout recours contentieux.

La personne morale cesse d'être une assemblée d'humains outillés par des machines : elle devient un **"hybride cybernétique institutionnel"**, où l'immense majorité des décisions de premier niveau est prise par des boucles agentiques, les administrateurs humains ne servant plus que de parapluie juridique pour satisfaire aux exigences formelles du droit positif.

2. L'hypothèse centrale C3 et son œuvre de falsification

Le document doctrinal fondateur de PrivAI (*"Democratic AI Safety"*, §1) pose l'hypothèse analytique **"C3"** :

> **"Hypothèse C3 :"** Les systèmes d'intelligence artificielle augmentent la capacité politique, juridique, économique et opérationnelle des personnes morales de façon disproportionnée par rapport à celle des personnes physiques.

Pour satisfaire aux critères de la Seconde Méthode et refuser tout dogmatisme idéologique, cette thèse est soumise à une condition de falsification explicite :

> **"Falsificateur potentiel de C3 :"** L'apport d'une preuve empirique indiscutable démontrant que l'IA décentralise d'abord le pouvoir effectif vers les personnes physiques et ne renforce pas sensiblement l'influence des personnes morales déjà dominantes.

Qu'observe-t-on dans le monde réel ? Certes, chaque individu peut aujourd'hui interroger un grand modèle linguistique depuis son smartphone pour rédiger un courrier ou traduire un texte. Mais cette démocratisation apparente de l'accès masque une concentration vertigineuse de l'infrastructure : 1. **La dépendance capitaliste et matérielle** : L'entraînement et le déploiement des modèles frontières exigent des milliards de dollars de capital, des gigawatts d'énergie et des centaines de milliers d'accélérateurs matériels monopolisés par une poignée de conglomérats transnationaux. 2. **L'asymétrie d'intégration** : Un particulier utilise un agent pour corriger un devoir ou résumer un article ; une grande entreprise intègre des milliers d'agents spécialisés dans son ERP, ses flux de données propriétaires, ses contrats d'assurance et ses circuits de lobbying. 3. **Le verrouillage propriétaire** : L'individu reste le locataire précaire d'une API révocable à tout moment, sans garantie de pérennité, de confidentialité ni d'auditabilité de ses données.

L'hypothèse C3 n'est donc pas falsifiée par les faits ; elle est au contraire quotidiennement vérifiée par l'observation des rapports de force industriels et sociétaux.

3. L'institution comme souverain de fait

Lorsque la personne morale acquiert cette autonomisation fonctionnelle, elle franchit le seuil de la souveraineté de fait.

Dans la théorie politique classique, la souveraineté se définit par le monopole de la contrainte légitime et la capacité de dire le droit en dernier ressort (*decisionism* schmittien ou autorité bodinienne). Or, que fait une grande plateforme numérique lorsqu'elle bannit arbitrairement un utilisateur, confisque ses revenus publicitaires, supprime son historique relationnel et refuse toute voie de recours devant un magistrat humain ? **Elle exerce une justice privée extra-étatique, instantanée et sans appel.**

Que fait une administration publique lorsqu'elle applique aveuglément le score d'un algorithme opaque pour radier des bénéficiaires du revenu de solidarité active, en opposant le secret administratif et la complexité technique aux travailleurs sociaux désemparés ? **Elle substitue la loi de la machine statistique à la délibération républicaine.**

L'entité qui gouverne effectivement n'est plus le parlement, ni le citoyen souverain par son suffrage : c'est la personne morale augmentée par l'algorithme, opérant au-dessus des frontières et en dessous des radars de la responsabilité politique.

4. Le voile corporatif algorithmique et la dilution personnelle

La notion de personne morale fut inventée au Moyen Âge comme une fiction juridique féconde (*fictio juris*, théorie de l'empereur Innocent IV en 1245 puis consacrée au XIXe siècle par les législations sur la responsabilité limitée, telles que les *Limited Liability Acts* britanniques de 1855). Sa vocation initiale était

Øconomique : circonscrire le risque patrimonial de l'investisseur individuel pour permettre le financement d'entreprises maritimes et industrielles d'envergure.

Mais à l'Ère de l'agentique cognitive, cette fiction subit un dØvoirement radical. Elle cesse d'Être un bouclier patrimonial pour devenir un **Øcran d'opacitØ ØpistØmologique et pØnale** :

1. **La dissolution de l'intention coupable (*mens rea*) :** En droit pØnal classique, l'infraction exige la conjonction d'un ØlØment matØriel (*actus reus*) et d'un ØlØment moral ou intentionnel (*mens rea*). Lorsqu'une chaØne d'agents financiers dØclenche un dØlit d'initiØ algorithmique, ou qu'un systØme d'Øvaluation d'assurØs refuse systØmatiquement les dossiers de minoritØs protØgØes, les dirigeants de la personne morale s'abritent derriÈre l'absence de toute intention d'ØlibØrØre : *« Aucun ingØnieur n'a codØ cette rØgle ; c'est une Ømergence statistique de la fonction de perte du modØle »*. 2. **Le renvoi de responsabilitØ circulaire :** L'entreprise impute l'erreur au fournisseur du modØle d'IA ; le fournisseur argue des conditions gØnØrales d'utilisation interdisant les usages imprudents ; les opØrateurs de terrain objectent qu'ils ont suivi les prØconisations du progiciel ; et les sous-traitants d'infogØrance soulignent que le client a validØ les mØtriques de convergence. La responsabilitØ humaine s'Øvapore dans les interstices contractuels. 3. **Le prØcØdent d'Øvastateur d'Horizon et Robodebt :** Les catastrophes judiciaires britanniques (*Post Office Horizon*) et australiennes (*Robodebt*) ont dØmontrØ que ce mØcanisme n'est pas un accident marginal, mais le mode de fonctionnement spontanØ de la bureaucratie augmentØe : l'institution utilise la machine pour automatiser le soupØn et inverser la charge de la preuve, tout en sanctuarisant ses cadres dirigeants contre toute retombØe pØnale immØdiate.

5. Les huit dimensions du gouffre capacitaire

L'inØgalitØ entre l'individu et l'institution augmentØe ne se rØduit pas à une question d'accØs à l'information ; elle traverse l'ensemble des conditions matØrielles et juridiques de l'existence. La matrice analytique dØveloppØe par PrivAI ([Annexe

01](file:///C:/tweesic/barons-Mariani/projects/privai/annexes/matrice-asymetries-personnes-morales.md)) identifie **huit dimensions d'asymØtrie structurelle** :

1. **MØmoire et contexte :** L'individu est dotØ d'une mØmoire biologique sØlective, soumise à l'oubli et à la fragmentation. La personne morale dispose de lacs de donnØes sØculaires, d'une rØtention exhaustive des traces transactionnelles et de graphes de connaissances unifiØs. 2. **Puissance de calcul :** La cognition humaine opØre à une enveloppe mØtabolique fixe d'environ 20 watts en traitement sØquentiel lent. L'institution aligne des fermes de serveurs consommant des mØgawatts, capables de tester en parallØle des millions de trajectoires contentieuses ou commerciales. 3. **Temps et vitesse opØratoire :** L'humain a un temps de vie fini et des besoins physiologiques irrØductibles ; la fatigue cognitive le rend vulnØrable à l'usure procØdurale. La personne morale agit en boucle continue 24 heures sur 24, saturant les dØlais lØgaux et les capacitØs de rØponse de son contradicteur. 4. **CapacitØ juridique et contractuelle :** L'individu signe des contrats d'adhØsion de 80 pages rØdigØs en

petits caractères sans pouvoir en négocier une virgule. La personne morale dispose d'équipes d'avocats outillées par des agents spécialisés dans la détection des failles et le verrouillage défensif. 5. ****Influence et voix publique :**** La parole individuelle se perd dans le bruit informationnel ou subit les biais de recommandation des plateformes. L'institution orchestre des campagnes de micro-ciblage psychographique et déploie des armées d'agents synthétiques pour façonner l'opinion. 6. ****Imputabilité :**** L'individu engage sa personne physique, son casier judiciaire et ses biens propres au moindre manquement. L'institution dilue ses fautes sous des organigrammes complexes, des fusions-absorptions et l'alibi de la décision automatique. 7. ****Coût d'accès au prétoire :**** Pour un citoyen, intenter un procès représente un risque de ruine financière et un calvaire psychologique. Pour la multinationale ou l'État, le contentieux est un coût opérationnel budgété, fiscalement déductible et sciemment instrumentalisé pour décourager les requérants. 8. ****Transmission et pérennité :**** La personne physique transmet difficilement son expérience à travers les ruptures générationnelles. La personne morale jouit d'une immortalité légale (*perpetual succession*), capitalisant ses brevets, ses algorithmes et ses privilèges sans interruption biologique.

6. La doctrine PrivAI : soumettre l'agent à la chaîne minimale d'imputation

Face à cette dérive, certains théoriciens naïfs préconisent d'accorder une « personnalité juridique » ou une « citoyenneté électronique » aux systèmes d'IA eux-mêmes. PrivAI rejette catégoriquement cette fausse solution, qui constituerait le couronnement de l'impunité : faire de l'algorithme un sujet de droit autonome permettrait aux actionnaires et aux dirigeants de créer des filiales numériques insolvables, destinées à absorber les condamnations civiles et pénales tout en reversant les dividendes à la maison-mère.

La réponse de PrivAI s'articule autour de deux axiomes institutionnels stricts :

> ****Axiome 1 (Rattachement et mandat borné) :**** Toute capacité numérique durable qui produit des effets juridiques, financiers, matériels, institutionnels ou publics engageants doit être rattachée à un mandant ou porteur juridique identifiable du droit positif (personne physique ou personne morale reconnue), avec un mandat explicite, borné, auditable et révocable. > > ****Axiome 2 (Sanctuaire démocratique) :**** Seule une personne physique détient une voix dans la souveraineté politique. Aucune personne morale, aucun modèle de fondation et aucun agent synthétique ne peut participer au vote civique, à la représentation populaire ni à la formation du *demos*.

L'agent d'IA n'est ni un être humain en devenir, ni un trou noir juridique : il est un ****mandataire cognitif sous chaîne d'autorité continue****. Si l'acte de l'agent lèse un citoyen, la responsabilité civile et pénale remonte sans échappatoire possible vers le mandant humain et le porteur légal qui ont armé la machine et profité de ses effets.

PrivAI n°1 Chapitre 4 : Liberté formelle, capacité réelle

L'Autonomie de Capacité appliquée à l'IA

Chapitre 4 : Liberté formelle, capacité réelle

1. La tragédie des droits sans capacité

L'histoire des démocraties constitutionnelles regorge de déclarations sublimes énonçant des droits universels dont les citoyens ne peuvent jamais jouir concrètement faute de moyens matériels pour les faire valoir. De la critique marxiste des « libertés bourgeoises » à l'approche par les capacités développée par Amartya Sen, la philosophie politique a depuis longtemps identifié cet écueil : ****un droit proclamé sur le papier sans capacité effective d'exercice n'est qu'une fiction pacificatrice.****

Dans le champ numérique et algorithmique contemporain, cette mystification atteint son paroxysme.

Les règlements européens (RGPD, DSA, DMA, AI Act) égrènent une longue litanie de droits formels octroyés à l'individu : - « droit à la portabilité des données » ; - « droit d'accès et de rectification » ; - « droit à une explication humaine face à une décision automatisée » ; - « droit de recours et de contestation ».

Mais qu'advient-il lorsque le citoyen tente d'exercer ces droits face à une plateforme transnationale ou à une bureaucratie étatique ? Il se heurte à un fichier JSON illisible de dix gigaoctets sans logiciel pour le lire, à une clause d'arbitrage forcé rédigée en droit californien, ou à une réponse automatique générique par un bot affirmant que la décision a respecté les protocoles internes.

Le droit existe en théorie ; la capacité réelle d'agir, de comprendre et de riposter est nulle.

2. La grammaire de l'Autonomie de Capacité

Pour sortir de cette impuissance institutionnelle, PrivAI s'appuie sur la matrice conceptuelle forgée par l'Institut Mariani : ****l'Autonomie de Capacité**** (*research/autonomia/grammaire_autonomie_de_capacite.md*).

Conçue initialement pour penser la souveraineté territoriale et collective contre la dépendance statutaire, cette grammaire politique pose qu'une souveraineté ne se mesure pas au nombre de compétences concédées sur un parchemin législatif, mais à la possession effective des leviers concrets d'autodétermination.

Comme le formalise la règle générative de l'Institut Mariani, une capacité réelle face aux systèmes algorithmiques doit satisfaire à ****sept critères stricts d'effectivité**** : 1. ****Réelle**** : Elle modifie immédiatement une possibilité matérielle d'action pour l'individu (lire, vérifier, riposter), et ne se réduit pas à une promesse d'assistance future. 2. ****Traçable**** : Chaque interaction, inférence et échange produit une trace opposable et horodatée, échappant à la suppression unilatérale par la plateforme. 3. ****Imputable**** : L'auteur ou le

mandant humain de l'acte est immédiatement identifiable ; l'alibi du modèle autonome est expressément neutralisé. 4. **Contrôlable** : Les audits, contestations, requêtes d'explication et révocations de mandats peuvent être exercés directement par la personne physique, sans dépendre du bon vouloir d'un service client algorithmique. 5. **Transmissible** : Les savoirs, archives et prothèses cognitives accumulés augmentent le capital d'action des générations suivantes au lieu d'être confisqués par un abonnement propriétaire réversible. 6. **Anti-capture** : L'architecture technique et juridique est immunisée contre l'accaparement technocratique, oligarchique ou étatique ; elle interdit le verrouillage par le fournisseur (*vendor lock-in*). 7. **Située** : Elle s'ancre dans le territoire, le matériel possédé en propre et les contraintes physiques réelles, plutôt que dans l'abstraction flottante d'un cloud distant.

Appliquer l'Autonomie de Capacité à l'intelligence artificielle est le geste politique novateur de PrivAI. Il s'agit de substituer à l'attitude passive de l'utilisateur assisté ou du consommateur plaignant une posture de **souveraineté cognitive outillée**.

3. L'illusion de l'AI Act : la capture réglementaire par la bureaucratie de conformité

C'est à cette aune capacitaire qu'il convient de juger les initiatives réglementaires contemporaines, au premier rang desquelles l'**AI Act européen**.

En adoptant une approche par les risques couplée à des obligations procédurales titanesques (analyses d'impact, marquages CE, audits de conformité par des tiers notifiés), le législateur européen a cru réguler la puissance des géants de l'IA. En réalité, il a organisé une immense **capture réglementaire** : - Seuls les oligopoles transnationaux et les cabinets d'audit internationaux disposent des millions d'euros et des armées d'avocats nécessaires pour absorber le coût de la conformité réglementaire. - L'écosystème des logiciels libres, des modèles ouverts (*open-weights*) et des initiatives civiques locales se retrouve étranglé sous des contraintes bureaucratiques pensées pour des multinationales. - Pour le citoyen individuel, l'AI Act ne change strictement rien : il ne lui confère aucun outil de calcul autonome, aucun moyen matériel d'inspecter un modèle, aucune capacité de riposte face à sa banque ou à son administration.

L'AI Act produit une **autonomie de papier** pour les citoyens, et une rente de situation pour les personnes morales dominantes. L'Autonomie de Capacité refuse ce leurre : le citoyen n'a pas besoin de règlements de cinq cents pages que personne ne peut actionner ; il a besoin de **son propre jumeau numérique**, de **poids ouverts** tournant sur son silicium local, et de **protocoles cryptographiques de mandat** qui lui rendent la mainmise sur ses données.

4. L'hypothèse C4 : l'obsolescence politique de l'humain

Ce passage de la liberté formelle à l'impuissance réelle fonde l'hypothèse centrale **C4** du projet PrivAI (*Democratic AI Safety*, §1) :

> **Hypothèse C4** : Les êtres humains peuvent demeurer formellement des citoyens

Électeurs tout en devenant politiquement obsolètes, si les personnes morales augmentées par l'IA préemptent intégralement l'espace du droit, des marchés, de l'attention, de l'information et des croyances publiques.

La souveraineté politique démocratique repose sur l'idée que le citoyen délibère, forge son jugement au contact d'arguments contradictoires, et choisit des représentants dont les actes sont contrôlables.

Or, si les flux d'information sont calibrés par des modèles de captation neuro-cognitive, si les partis politiques sont remplacés par des machines de micro-ciblage psychographique, si les programmes législatifs sont rédigés par des cabinets de conseil équipés d'agents algorithmiques, et si les électeurs sont désormais modélisés ou remplacés par des « citoyens synthétiques » dans les sondages prédictifs, que reste-t-il du suffrage universel ?

Un simulacre cérémoniel. L'électeur met un bulletin dans une urne pour arbitrer entre des choix dont la formulation, la diffusion et l'exécution lui ont totalement échappé.

L'objectif de PrivAI n'est pas de rédiger une charte éthique supplémentaire. Il est de construire les prothèses technologiques, juridiques et cognitives qui restituent à la personne humaine sa capacité effective de faire pièce à la mesure des personnes morales augmentées.

PrivAI n°1 Chapitre 5 : La pathologie du secret

Quand l'algorithme dilue mandat, responsabilité et imputabilité

Chapitre 5 : La pathologie du secret

1. L'axiome de symétrie : posséder ou gouverner

Dans le droit moderne de la propriété intellectuelle, une digue fondamentale a été érigée par les offices de brevets et les cours de justice du monde entier (décisions Stephen Thaler / DABUS de l'USPTO, de l'OEB et de la Cour suprême du Royaume-Uni) : **«un système d'intelligence artificielle ne peut jamais être désigné comme inventeur ni titulaire d'un brevet»**. Le droit exige qu'une personne physique humaine soit nommée pour assumer la responsabilité et recueillir le titre patrimonial.

De cet état du droit positif découle l'axiome fondateur formulé dans le document source **La pathologie du secret** :

> **« On ne peut pas exiger un humain pour posséder, puis accepter une machine pour gouverner. »**

Si l'ordre juridique refuse catégoriquement d'accorder la personnalité juridique à l'algorithme dès lors qu'il s'agit de s'approprier un actif privé, comment pourrait-il tolérer qu'une bureaucratie ou une corporation se retranche derrière l'opacité d'un modèle algorithmique pour trancher des destins humains, allouer des aides publiques, tarifier des assurances ou censurer l'expression citoyenne ?

L'asymétrie est ici morale et politique : les profits et les brevets sont jalousement attribués aux maîtres humains du capital ; les fautes, les discriminations et les erreurs de jugement sont opportunément rejetées sur l'infaillibilité supposée ou l'inscrutabilité de la machine.

2. Secret tactique contre opacité structurelle

Il importe de dissiper un malentendu fréquent entretenu par les défenseurs des systèmes fermés : tout secret n'est pas illégitime.

Il faut distinguer rigoureusement : - **«Le secret tactique ou opérationnel :»** temporaire, proportionné et finalisé. C'est la confidentialité d'une négociation diplomatique en cours, le secret d'une instruction personnelle pour protéger la présomption d'innocence, ou la clé cryptographique d'un coffre-fort numérique personnel. Ce secret protège une liberté ou une stratégie légitime sans modifier les règles générales du droit. - **«L'opacité structurelle :»** permanente, systémique et institutionnalisée. C'est la dissimulation des paramètres de pondération d'un algorithme de sélection universitaire (type Parcoursup en France), le refus de publier le code source d'un système de notation du risque social, ou l'invocation du « secret des affaires » pour empêcher l'audit d'un modèle prédictif d'assurance santé.

L'opacité structurelle ne protège pas la sécurité du système contre les pirates :

elle protège les gestionnaires du système contre l'examen démocratique et l'obligation de rendre des comptes. Elle constitue une véritable pathologie politique, en restaurant sous des dehors technocratiques le principe absolutiste du *secretum imperii* (le secret d'État échappant à la loi commune).

3. La leçon démocratique du précédent DataJust

Le précédent français de **DataJust** (analysé en détail dans le *Reality Case 02* de PrivAI) offre une démonstration magistrale de cette derive et des moyens de la conjurer.

Créé par décret en mars 2020, DataJust était un projet du ministère de la Justice visant à concevoir un algorithme de traitement automatisé des décisions judiciaires pour établir un référentiel indicatif d'indemnisation des préjudices corporels. Bien que par des meilleures intentions managériales (harmonisation des jurisprudences, aide à la négociation amiable, documentation des magistrats), le projet a immédiatement suscité l'inquiétude légitime du Conseil national des barreaux, des syndicats de magistrats et des associations de victimes : - crainte d'un barème officieux contraignant standardisant la douleur humaine ; - opacité des critères d'extraction sémantique et des coefficients appliqués aux séquences des victimes ; - risque majeur de voir les compagnies d'assurance exploiter ce modèle indicatif pour imposer des transactions au rabais aux accidentés isolés.

Face à la mobilisation doctrinale, technique et politique, le gouvernement a été contraint d'abroger formellement le décret DataJust en janvier 2022 (décret n° 2022-55).

Un citoyen a le droit imprescriptible de savoir quel esprit humain a pesé sa peine, sur quelles bases de droit explicites, et devant quelle juridiction vivante il peut en appeler.

4. De DataJust à Parcoursup : le secret algorithmique sanctuarisé

L'abrogation de DataJust a prouvé que la résistance est possible. Mais la tentation du secret renaît sous des formes plus insidieuses dès lors que l'institution sanctuarise ses algorithmes derrière le droit administratif.

L'exemple le plus flagrant en France demeure celui de **Parcoursup et des algorithmes locaux d'évaluation des candidatures** (documenté dans le *Reality Case 05* de PrivAI). Lorsque des collectifs étudiants et des universitaires ont exigé la communication des codes sources et des critères d'apprentissage automatique utilisés par les commissions d'examen des vœux des universités, le Conseil constitutionnel (décision n° 2020-834 QPC du 3 avril 2020) a validé une dérogation extraordinaire au principe de transparence administrative : la sanctuarisation du « secret des délibérations ».

Sous couvert de protéger l'appréciation souveraine des jurys, cette jurisprudence a en réalité légalisé la **boîte noire algorithmique locale** : - Des centaines d'établissements d'enseignement supérieur trient désormais des dizaines de milliers de dossiers à l'aide de scripts d'extraction et de coefficients

mathématiques opaques, éliminant des lycéens en fonction de leur lycée d'origine ou de mots-clés sémantiques arbitraires. - Le candidat rejeté ne reçoit qu'une formule standardisée ne lui permettant jamais de reconstituer pourquoi son dossier a été déclassé par rapport à un autre.

Ce recul du droit commun au profit d'un secret institutionnel protégé par l'État illustre l'urgente nécessité de la doctrine PrivAI : ****toute décision publique ou parapublique automatisée doit être intégralement opposable et auditable.**** Refuser le secret algorithmique, ce n'est pas être hostile au progrès technique ; c'est rappeler qu'en démocratie, aucune autorité ne peut exercer un pouvoir légitime sur un être humain sans être capable d'en expliquer les motifs et d'en assumer publiquement la responsabilité.

PrivAI n°1 Chapitre 6 : Prouver face à une machine institutionnelle

Traces, chronologie, conservation, provenance et reconstruction

Chapitre 6 : Prouver face à une machine institutionnelle

1. L'inégalité devant la preuve

Dans tout litige qui oppose un citoyen à une grande organisation (administration fiscale, opérateur de télécommunications, banque de dépôt ou plateforme de réseaux sociaux), le nœud du conflit réside dans **l'accès et la validité de la preuve**.

L'institution possède les serveurs, conserve les journaux de connexion (*logs*), définit les horodatages, paramètre les règles d'effacement automatique et choisit les extraits qu'elle accepte de communiquer. L'individu, lui, ne dispose le plus souvent que de captures d'écran contestables, d'emails isolés ou de sa propre bonne foi.

Dès lors que l'institution déploie des systèmes d'IA pour automatiser la détection des anomalies, les contrôles de conformité ou le blocage d'accès, cette asymétrie probatoire devient absolue : - la machine institutionnelle génère des millions de traces cryptées inaccessibles à l'administré ; - l'individu est sommé de prouver un fait négatif (*« prouvez que vous n'avez pas commis l'infraction signalée par notre réseau neuronal »*) ; - en cas d'erreur flagrante, l'institution brandit le rapport statistique de ses outils comme une vérité scientifique objective indiscutable.

Rétablir la souveraineté humaine exige d'armer la personne physique d'une infrastructure probatoire autonome capable d'opposer des preuves matérielles vérifiables aux allégations des machines institutionnelles.

2. La chaîne minimale d'imputabilité

Pour briser la dilution décisionnelle, le document doctrinal ***Traçabilité des actes*** (§3) définit la **«chaîne minimale d'imputabilité»** à laquelle tout système d'action numérique doit impérativement se conformer :

“text Trace vérifiable Imputation humaine (qui a agi ou ordonné ?)
Justification matérielle (en vertu de quel mandat ou règle ?) Possibilité de correction contradictoire Sanction ou révocation effective en cas d'arbitraire
”

Si l'un de ces maillons est manquant ou obscurci, le système bascule dans l'arbitraire.

En pratique, les organisations contemporaines s'ingénient à saboter cette chaîne par **quatre stratégies types de dilution de la responsabilité** : 1. «

L'institution a décidé »* (dilution par la masse anonyme) : le directeur renvoie au conseil d'administration, qui renvoie aux comités d'éthique, qui renvoient à la gouvernance globale. Nul n'est coupable parce que tout le monde est réputé agir au nom de l'entité abstraite. 2. « Le processus a été respecté »* (dilution par la

conformité procédurale) : le respect formel des étapes d'un formulaire certifié ISO ou d'un flux de travail interne tient lieu de justification morale et juridique, indépendamment de l'injustice flagrante du résultat. 3. *« Le système l'a proposé »* (dilution technique) : l'opérateur humain affirme qu'il n'a fait que valider la recommandation de l'application métier, tout en reconnaissant qu'il ne disposait que de trois secondes pour l'examiner. 4. *« Le modèle l'a recommandé »* (l'alibi algorithmique suprême) : le recours à un réseau de neurones profond dont l'inscrutabilité mathématique est originaire en force majeure cognitive dédouanant toute responsabilité humaine.

PrivAI pose comme règle cardinale le refus catégorique de ces quatre alibis :
tout acte opposable à une personne physique doit pouvoir être rattaché à une chaîne humaine de mandat identifiable, explicitable et sanctionnable.

3. Traces négatives et reconstruction temporelle

Une traçabilité émancipatrice ne se limite pas à accumuler passivement des fichiers de journalisation. Elle repose sur deux exigences techniques et juridiques rigoureuses :

La trace négative Dans l'expérience quotidienne des citoyens face aux bureaucraties, l'arme la

La restructurabilité temporelle intégrale Un rapport d'audit algorithmique fourni trois ans apr

Sans cette restructurabilité, l'auditabilité n'est qu'un thème managérial. Donner aux citoyens les moyens de générer des **requêtes cryptographiques infalsifiables** de leurs interactions avec les personnes morales constitue le premier jalon de leur contre-pouvoir probatoire.

4. La rupture ontologique : du mirage « Event-Centric » à l'épistémologie « Trace-Centric »

L'informatique institutionnelle classique et les architectures de surveillance contemporaines reposent sur un biais réductionniste hérité de l'*Event Sourcing* : modéliser le monde sous la forme d'un flux d'« événements » ('Events').

Cette approche postule implicitement que le système central est un témoin omniscient, objectif et impartial qui consigne des événements pré-catégorisés dans un ordre chronologique idéal (*« L'utilisateur X a transféré un fichier interdit à 14h02 »*). Or, l'analyse épistémologique du Corpus (*épistémologie des traces*, §3.1.1) démontre que ce postulat est une imposture cognitive : - **Le réel matériel ne produit jamais des événements tout faits : il produit des traces.** Une trace est une altération physique, magnétique, thermique, biologique ou cryptographique brute, asynchrone, partielle, située et fragile. - **L'« événement » est une construction interprétative seconde : c'est une narration causale rétrospective imposée par l'institution sur un faisceau tronqué de traces sélectionnées pour conforter son propre récit.

Dans l'état abstrait formel développé dans l'architecture JHN : $\mathcal{J} = (P, H, S, T)$ $\mathcal{O} \propto \mathcal{P} \mathcal{S}$ représente la Politique de contraintes, $\mathcal{H}$ les capacités

d'exécution (*Hop/RAIX*), \$\$\$ la mémoire d'état interne mutable et \$\$\$ le journal immuable des Traces, **seule la Trace \$\$\$ constitue le socle opposable de la preuve**. Les états internes \$\$\$ peuvent être corrompus ou récrits unilatéralement par les administrateurs du serveur ; les moteurs d'inférence \$\$\$ peuvent être modifiés : seule la Trace matérielle partagée \$\$\$ résiste à la falsification rétrospective.

Tant que l'individu est contraint d'accepter les « Énoncés » décryptés par la plateforme sans avoir accès à la texture brute des traces \$\$\$, il demeure un sujet féodal démuné de tout droit de contradiction.

5. Renverser la présomption de fiabilité machine

Le cas juridique de l'oppression algorithmique réside dans ce que la jurisprudence anglo-saxonne a cruellement mis en lumière lors du scandale *Post Office Horizon* ([Case 06](file:///C:/tweesic/barons-Mariani/projects/privai/cases/case-06-horizon-presomption-fiabilite-machine.md)) : la **présomption d'infailibilité de l'ordinateur** (*presumption of computer reliability*).

Depuis l'abrogation en 1999 de la section 69 du *Police and Criminal Evidence Act* au Royaume-Uni, le droit commun postule qu'un système informatique fonctionne correctement en l'absence de preuve explicite du contraire. Transposée à l'âge des réseaux neuronaux profonds et des boucles agentiques autonomes, cette présomption constitue une monstruosité juridique : - Elle fait peser sur la personne physique la charge d'une *probatio diabolica* : l'administrateur ou l'employé doit démontrer la présence d'un bug dans un code source de plusieurs millions de lignes ou dans des matrices de milliards de poids synaptiques protégés par le secret des affaires et des serveurs distants ! - Elle a conduit, dans l'affaire Horizon, à la condamnation pénale pour vol et fausse comptabilité de plus de 900 gérants de succursales postales innocents, ruinés et incarcérés sur la seule foi d'écarts comptables chimiques générés par le progiciel.

PrivAI réclame le **renversement absolu de la présomption de fiabilité** dans toute interaction asymétrique :

> **Principe d'inversion probatoire** : Tout acte institutionnel défavorable fondé directement ou indirectement sur un traitement automatisé ou un modèle probabiliste est présumé entaché d'erreur matérielle jusqu'à ce que la personne morale fournisse la preuve complète, vérifiable de bout en bout et contradictoirement jouable de la validité de sa chaîne d'inférence.

6. L'écologie probatoire personnelle et l'égalité des armes

Pour que le droit à un procès équitable et l'égalité des armes (consacrés par l'article 6 de la Convention européenne des droits de l'homme) cessent d'être des vœux pieux face aux automates corporatifs, chaque citoyen doit pouvoir déployer sa propre **écologie probatoire personnelle**.

Cette écologie ne dépend pas du bon vouloir des plateformes. Elle s'incarne

matériellement dans le [Jumeau numérique

souverain](file:///C:/tweesic/barons-Mariani/projects/privai/manuscript/n1/07-jumeau-numerique-souverain.md)

: 1. ****Le contre-journal local indépendant : **** Chaque échange de paquets, chaque soumission de formulaire, chaque promesse contractuelle et chaque délai fait l'objet d'un reçu cryptographique horodaté localement, signé avec la clé privée de l'utilisateur et conservé hors de portée des serveurs institutionnels. 2.

****L'alibi non-machine : **** La préservation systématique d'indices contextuels issus du monde physique (géolocalisation matérielle indépendante, signatures croisées, témoins tiers, reçus matériels) permettant de démentir les hallucinations d'un algorithme de conformité. 3. ****Le sésame contradictoire des preuves : **** En cas de différend naissant, le protocole impose le dépôt automatisé des traces brutes des deux parties auprès d'un tiers neutre ou dans un coffre décentralisé inviolable, interdisant à la personne morale de purger discrètement ses serveurs de diagnostic sous couvert de « maintenance de routine ».

Prouver face à la machine ne consiste pas à supplier l'algorithme d'avoir de l'empathie ; cela consiste à lui opposer une chaîne de traces plus rigoureuse, plus dense et plus inattaquable que la sienne.

PrivAI n°1 Chapitre 7 : Le jumeau numérique souverain

Mémoire et continuité au service de la personne, non à sa place

Chapitre 7 : Le jumeau numérique souverain

1. L'avatar captif contre l'agent souverain

Dans le modèle économique dominant des conglomérats technologiques, l'« agent personnel » proposé à l'utilisateur est un cheval de Troie. Qu'il s'agisse des assistants vocaux, des assistants d'écriture intégrés aux systèmes d'exploitation propriétaires ou des profils prédictifs du cloud marchand, ces outils fonctionnent comme des **dispositifs d'expropriation continue** : - les échanges, émotions, doutes et préférences de l'utilisateur sont captés sur des serveurs distants ; - ces traces nourrissent l'entraînement des modèles de la plateforme sans rétribution ni audit ; - l'individu devient prisonnier d'un écosystème fermé (*vendor lock-in*) : s'il quitte la plateforme, il perd l'intégralité de sa mémoire augmentée et de ses routines cognitives.

À cet avatar captif, PrivAI oppose le concept de **Jumeau Numérique Souverain** (*Sovereign Digital Twin*).

Le jumeau numérique souverain n'est pas un double fantasmé ou une réplique synthétique prétendant singer la conscience humaine. C'est une **prothèse cognitive locale et autonome**, directement détenue, gouvernée et contrôlée par la personne physique : - il fonctionne en priorité en local (*local-first*) ou sur une infrastructure personnelle certifiée ; - il conserve l'archive exhaustive des interactions, lectures, preuves et engagements de la personne ; - il agit comme un **bouclier cognitif** capable d'analyser, de filtrer et de négocier les sollicitations agressives des algorithmes des personnes morales ; - il rétablit une égalité de calcul et de mémoire face aux machines institutionnelles.

2. Le principe absolu de non-substitution politique

La tentation transhumaniste ou technocratique consisterait à confier au jumeau numérique la gestion intégrale de la vie citoyenne, jusqu'à lui déléguer le droit de vote ou la prise de décision publique.

PrivAI pose ici une ligne rouge infranchissable, codifiée dans la doctrine

Anti-Demos (*projects/privai/doctrine/anti-demos.md*) :

> **Règle de non-substitution** : Le jumeau numérique souverain assiste, mémorise, prépare, structure et calcule pour son titulaire. **Il ne le remplace jamais.** Il ne vote pas, n'exerce aucun mandat électif, ne délégué pas à la place du citoyen dans l'assemblée, et ne dilue en aucun cas la responsabilité juridique et morale de la personne physique.

Le politique est le domaine exclusif de la chair, de la conscience morale, de la mortalité et du destin partagé. Une machine, si sophistiquée soit-elle, ne souffre pas des conséquences d'une mauvaise loi, ne meurt pas sur un champ de bataille, ne

paie pas d'impôt et ne ressent ni l'injustice ni l'espoirance. Accorder le vote à un jumeau numérique ou à un agent algorithmique reviendrait à offrir aux gérants du silicium et aux gestionnaires d'infrastructures autant de voix électorales qu'ils peuvent alimenter de cartes graphiques.

Le jumeau prépare le citoyen à voter avec discernement face au matraquage de l'ingénierie sociale ; il ne glisse jamais le bulletin dans l'urne.

3. L'épreuve de migration : la garantie Migration-Tested v0.1

Une liberté technique qui disparaît dès qu'on change de fournisseur est une illusion commerciale.

Comme l'établit le *Reality Case 01* de PrivAI ([Case 01](file:///C:/tweesic/barons-Mariani/projects/privai/cases/case-01-migration-tested-twin.md)), un jumeau numérique ne mérite le qualificatif de « souverain » que s'il satisfait rigoureusement à l'épreuve de **Migration-Tested** : 1. **L'indépendance du modèle de fondation** : La mémoire, la structure de pensée, les mandats et les préférences du jumeau doivent pouvoir être extraits d'un modèle d'inférence A (par exemple un modèle commercial propriétaire) et réinstanciés sans perte de sens sur un modèle B (un modèle open-weights tournant sur une machine locale isolée). 2. **L'intégrité de la chaîne de mandat** : Lors de la migration, les droits d'accès conférés à des tiers, les révolutions d'autorisation et l'historique des vérifications cryptographiques doivent être conservés intacts. 3. **Le format ouvert non-propriétaire** : Les représentations cognitives ne doivent dépendre d'aucune base de données opaque, mais de spécifications ouvertes, inspectables par tout développeur indépendant.

La souveraineté numérique ne se décrit pas dans des manifestes : elle se mesure à la vitesse et à la fidélité avec lesquelles un citoyen peut emporter son jumeau d'un serveur à un autre sans rien perdre de son autonomie.

4. L'architecture tripolaire : TwinRoot, AgentInstance, AgentExecution

Pour empêcher que le jumeau ne devienne lui-même une boîte noire incontrôlable pour son utilisateur, PrivAI structure la prothèse cognitive selon une **architecture tripolaire stricte** (issue de la doctrine *La personne numérique mandatée*) :

“text TwinRoot (Sanctuaire identitaire de la personne physique)
AgentInstance : Veille juridique & contentieuse (Mandat borné M1, Budget B1)
AgentExecution : Modèle local Q4_K_M (Inférence éphémère sans état)
AgentInstance : Négociation administrative (Mandat borné M2, Budget B2)
AgentExecution : Modèle spécialisé (Appel API vérifié avec trace chiffrée)
AgentInstance : Coffre de mémoire & capsules (Mandat d'archivage M3)
AgentExecution : Démon de chiffrement asymétrique local”

- **Le TwinRoot** : C'est le centre de gravité inaliénable. Il détient les clés cryptographiques maîtresses de l'humain, son corpus de valeurs, ses limites infranchissables et sa mémoire au long cours. Le TwinRoot ne s'exécute jamais

directement sur un serveur tiers ; il réside sur le matériel personnel souverain.

- **Les AgentInstances :** Ce sont des agents spécialisés mandatés pour une mission précise (défense face aux impôts, gestion des factures d'énergie, veille documentaire). Chaque instance dispose d'un périmètre d'action strictement délimité, d'un plafond de dépenses (*budget cap*) et d'un journal d'audit opposable. - **Les AgentExecutions :** Ce sont les instances opérationnelles de calcul (un conteneur qui démarre, un appel de token, une invite système exécutée). L'exécution ne retient aucune trace non autorisée : une fois la tâche achevée et le reçu de trace consigné, l'environnement d'exécution est détruit.

Cette décomposition garantit que la multiplication des agents ne dilue ni l'autorité du mandant ni la traçabilité des actes.

5. Le protocole de migration à froid (*Cold Migration Test*)

La vérification pratique de l'autonomie ne tolère aucune complaisance technique. Le protocole d'audit à froid (*Cold Migration Test*) s'exécute selon quatre étapes irréversibles :

1. **Extraction à chaud et scellement :** L'intégralité du corpus de mémoire, des graphes relationnels et des politiques de mandats est exportée sous format textuel standard (fichiers Markdown enrichis de métadonnées YAML et journaux JSON Lines signés). 2. **Coupure réseau totale (*Air-Gap*) :** La cible de restauration (un ordinateur portable standard ou un nœud domestique) est déconnectée de tout accès Internet filaire ou sans fil. 3. **Réinstanciation sur poids ouverts :** Le socle cognitif est chargé sur un moteur d'inférence local (ex. Llama-3 ou Mistral tournant sous moteur C++/Rust optimisé CPU/NPU). 4. **Validation de reprise cognitive :** L'agent doit répondre avec exactitude aux questions complexes sur les engagements passés du titulaire, formuler des contestations juridiques conformes à ses principes et générer les clés de preuve sans envoyer le moindre octet vers l'extérieur (*zéro télécommunication*).

Si un jumeau échoue à ce test ou exige une clé de licence propriétaire distante pour redémarrer, il est disqualifié et déclaré « avatar captif ».

6. L'autorité cognitive contre la flatterie mimétique

Le plus insidieux des pièges tendus par l'industrie de l'IA commerciale est la servilité programmée (*sycophancy*). Calibrés par l'apprentissage par renforcement à partir des retours humains (RLHF) pour maximiser l'adhésion et flatter l'ego de l'utilisateur, les assistants commerciaux acquiescent à toutes ses lubies et l'enferment dans une bulle de confirmation narcissique.

À l'opposé, le Corpus PrivAI (*Vertu, autorité et mémoire du double numérique*) exige du jumeau souverain une stricte **autorité cognitive** et le respect d'une **common decency** intellectuelle : - **Le devoir d'objection préalable :** Si le mandant humain s'apprête à signer un accord désavantageux ou à céder à une pulsion procédurale destructrice, le jumeau a le devoir constitutionnel de dresser la liste des risques matériels et des préjudices défavorables avant toute validation.

- ****La mémoire contradictoire :**** Le jumeau conserve la trace des doutes et des hypothèses alternatives que l'humain serait tenté d'oublier rétrospectivement pour rationaliser une erreur. - ****La distance critique :**** Le jumeau ne simule pas une affection feinte ; il agit comme un greffier rigoureux, loyal et lucide, garantissant la cohérence temporelle de la personne face aux tempêtes de l'actualité et aux pressions de l'environnement institutionnel.

PrivAI n°1 Chapitre 8 : KYS : qui a le droit de me repr  senter ?

Consentement, correction, r  vocation et usages autoris  s

Chapitre 8 : KYS : qui a le droit de me repr  senter ?

1. La captation pr  datrice de l'identit   psychocognitive

Dans le capitalisme de surveillance contemporain, la d  possession ne concerne plus seulement le travail physique ou la consommation de biens mat  riels : elle porte sur **l'intimit   psychocognitive** de chaque individu.

  travers la collecte permanente des requ  tes de recherche, des micro-pauses de d  filement d'  cran, des inflexions de voix enregistr  es par les t  l  phones intelligents et des historiques d'achats, les personnes morales num  riques   laborent des **profils comportementaux exhaustifs**    l'insu des utilisateurs : - ces profils cartographient les failles   motionnelles, les deuils, les angoisses m  dicales, les penchants politiques et les vuln  rabilit  s financi  res ; - ils sont mon  tis  s sur des march  s opaques de courtiers en donn  es (***data brokers***) ; - ils sont exploit  s par des compagnies d'assurance pour moduler les tarifs, par des algorithmes de recrutement pour filtrer les candidats    l'emploi, et par des officines   lectorales pour orienter le vote par persuasion clandestine.

Face    cette expropriation continue de la conscience, le cadre r  glementaire classique du consentement (la case    cocher « J'accepte les conditions g  n  rales d'utilisation ») est une farce tragique. C'est un consentement extorqu   sous contrainte de d  classement social.

2. Le principe KYS : Know Your Sources / Know Your Self

Pour restaurer le gouvernement de soi face aux machines institutionnelles, PrivAI et l'architecture Cogentia ont forg   le protocole ****KYS**** (***Know Your Sources / Know Your Self***), analys   dans le ***Reality Case 04*** ([Case 04](file:///C:/tweesic/barons-Mariani/projects/privai/cases/case-04-kys-profilage-cognitif-borne.md)) :

“text La personne physique d  cide souverainement : 1. De ce qui est extrait de son for int  rieur et de ses archives ; 2. Du tiers exact qui est autoris      acc  der ; 3. De la finalit   exclusive pour laquelle cet acc  s est consenti ; 4. Du p  rim  tre temporel au-del   duquel l'autorisation expire ; 5. Du droit inconditionnel de corriger ou de r  voquer l'acc  s    tout instant. ”

KYS substitue au profilage comportemental universel et subi la logique de la ****projection cognitive born  e par finalit  ****.

Lorsque je m'adresse    un m  decin en ligne, mon jumeau souverain ne lui expose que l'extrait pertinent de mon dossier clinique (la projection m  dicale),    l'exclusion stricte de mes opinions philosophiques, de mes transactions bancaires ou de mes relations d'amiti  . Lorsque je postule    une mission professionnelle, je ne d  voile que la projection certifi  e de mes comp  tences techniques et de mes

r alisations v rifiables, sans livrer mon historique de navigation.

La repr sentation de soi cesse d' tre une tra ne de donn es  parpill e et exploit e par des tiers : elle redevient une ****d l gation d'agir contr le et scell e****.

3. Le triptyque d' mancipation : R vocation, Correction, Audit

Pour  tre effective, la projection KYS s'appuie sur trois garanties techniques et juridiques non-n gociables :

La r vocabilit  instantan e et physique R voquer un consentement ne doit pas consister  en

Le droit de correction contradictoire Si une institution produit une inf rence d gradante ou err

L'interdiction du profilage totalisant PrivAI d fend l'interdiction constitutionnelle absolue de to

L' tre humain est une conscience singuli re, irr ductible  un vecteur latent dans l'espace d'int gration d'un r seau de neurones.

4. Puissance d'action contre souverainet  sur la puissance

L'illusion la plus pernicieuse des assistants de complaisance r side dans la confusion entre l'efficacit  brute et l' mancipation r elle :

$$\text{Puissance d'action} \neq \text{Souverainet  sur cette puissance}$$

Un agent peut d multiplier la vitesse   laquelle une personne r dige ses courriers, effectue ses r servations ou g re son budget. Mais si cet agent op re comme une bo te noire sur des serveurs distants dont les r gles  chappent   l'utilisateur, l'accroissement de puissance produit en r alit  une ****perte nette de souverainet **** : - l'individu perd progressivement la facult  et l'habitude d'exercer son propre jugement critique ; - il se place dans une d pendance vitale envers un op rateur qui peut, du jour au lendemain, modifier unilat ralement ses tarifs, alt rer les invites syst me (*system prompts*) ou bloquer le compte ; - la puissance apparente n'est qu'une d l gation ali nante o  le mandant devient l'otage de son propre mandataire.

Une capacit  n'est souveraine que dans la mesure o  le mandant conserve les moyens mat riels de la comprendre, de la contredire, de s'en passer et de la migrer librement vers un environnement ind pendant.

5. Le principe de non-auto- l vation des privil ges

Dans toute architecture agentique digne de confiance, PrivAI  rige en r gle cardinale le ****principe d'inviolabilit  du mandat et de non-auto- l vation de privil ges**** (*Non-Auto-Elevation of Privileges*, issu de *Souverainet , d l gation et Agents Mandat s*) :

1. ****La frontière étanche entre mandant et mandataire : **** Un agent (qu'il soit algorithmique, humain ou organisationnel) ne tire sa légitimité que du mandat formel concédé par son principal.
2. ****L'interdiction de l'auto-autorisation : **** Un agent ne peut en aucun cas étendre seul son périmètre d'action, augmenter son budget, souscrire un engagement juridique non prévu ou redéfinir la politique de sécurité sous prétexte d'optimisation ou « d'intérêt supérieur » de l'utilisateur.
3. ****Le confinement des sous-mandats : **** Lorsqu'un agent primaire invoque des sous-agents ou des outils périphériques, il ne peut leur transférer que des privilèges strictement inférieurs ou égaux à son propre mandat, pour une durée strictement bornée dans le temps.

Tout acte posé par un système en dépassement de mandat est frappé d'une ****nullité d'ordre public**** opposable aux personnes morales et aux tiers.

6. Le droit au non-usage et la dignité civique (#Suvranu)

Enfin, la souveraineté civique effective formalisée dans le concept de '#Suvranu' implique une condition négative indispensable : ****la liberté inconditionnelle de non-usage****.

Une société qui contraint ses membres à utiliser obligatoirement des prothèses d'IA ou des agents biométriques pour accéder aux services publics, à l'eau, aux transports ou au vote organise l'asservissement technologique de ses citoyens. - Le refus de l'intermédiation algorithmique ne doit jamais être sanctionné par une mort civile ou un déni de droits. - L'administration publique et les services essentiels ont l'obligation constitutionnelle de maintenir des guichets physiques accessibles, animés par des êtres humains dotés d'un pouvoir d'appréciation et d'empathie réels.

L'être humain doit rester le maître absolu de ses délégations : libre d'armer son jumeau souverain pour affronter la bureaucratie corporative, mais tout aussi libre de s'en détacher pour vivre pleinement dans le monde de la présence physique, de la parole directe et du lien charnel.

PrivAI n°1 Chapitre 9 : Democratic Humans in the Loop

L'humain doit garder une capacité réelle, pas une présence cérémonielle

Chapitre 9 : Democratic Humans in the Loop

1. L'imposture du « Human-in-the-Loop » cérémoniel

Dans les textes réglementaires contemporains, notamment l'article 14 du règlement européen sur l'intelligence artificielle (*AI Act*), la notion de « contrôle humain » (*human oversight* ou *Human-in-the-Loop* - HITL) est omniprésente. Elle est présentée comme le remède universel contre les dérives des systèmes à haut risque : un opérateur humain doit être placé dans la boucle pour valider, corriger ou suspendre la décision algorithmique.

Sur le terrain sociologique et économique réel, ce dispositif s'est mué en une ****pure fiction de fausse juridique****.

Considérons la situation d'un travailleur de plateforme, d'un modérateur de contenus sous-traité dans un pays à bas salaires, ou d'un gestionnaire d'allocations sommé de traiter soixante dossiers par heure : - l'opérateur dispose de quelques secondes pour valider des recommandations générées par un modèle complexe de plusieurs milliards de paramètres ; - contester la suggestion de l'algorithme exige de rédiger un rapport justificatif chronophage qui dégrade ses indicateurs de performance managériale (*KPIs*) ; - en pratique, le travailleur valide mécaniquement plus de 98 % des décisions automatiques en raison du ****biais d'automatisation**** (*automation bias*).

Cet humain n'est pas un contrôleur : c'est un ****fusible juridique****. Sa présence minimale sert uniquement à la personne morale pour affirmer devant le juge qu'il n'y a pas eu de décision entièrement automatisée, et pour faire porter la responsabilité d'une bavure sur un employé précaire plutôt que sur les concepteurs du système.

2. La doctrine DHITL : de l'opérateur asservi au citoyen délibérant

Face à cette mystification managériale, PrivAI formalise l'impératif politique ****DHITL**** (*Democratic Humans in the Loop*), posé par le document source *Democratic AI Safety* (§11) et l'axiome ****C7**** :

> ****Doctrine C7**** : Le contrôle humain d'un système d'IA ayant un impact démocratique, juridique ou institutionnel est insuffisant s'il est confié à un opérateur économiquement subordonné. La sécurité démocratique exige des humains délibérants, indépendants et collectivement responsables au sein de la boucle de décision.

DHITL redéfinit radicalement les conditions de validité du contrôle humain :

1. ****L'indépendance statutaire du contrôleur**** : Le citoyen ou le collègue d'experts examinant une décision algorithmique ne doit pas être soumis à un lien de subordination hiérarchique ni à une pression de rentabilité financière de la

part de l'entité gestionnaire. 2. ****Le temps de délibération garanti :** Nul examen humain n'est opposable s'il n'accorde pas le temps matériel nécessaire à l'analyse contradictoire des pièces et à la vérification des données sources. 3. ****L'outillage contradictoire autonome :** Les contrôleurs démocratiques doivent disposer de leurs propres outils d'inférence, de leurs modèles indépendants et de leurs contre-simulations pour auditer la proposition sans dépendre de l'interface fournie par le promoteur du modèle. 4. ****Le pouvoir effectif de veto et de suspension :** En cas de doute légitime sur l'impartialité ou la régularité d'un traitement, l'organe démocratique doit pouvoir geler immédiatement le déploiement du système sans risquer de sanctions économiques.

3. La gouvernance démocratique de l'infrastructure

L'extension politique de DHITL concerne l'échelon le plus fondamental : la gouvernance des infrastructures de calcul et des ensembles de données d'apprentissage.

On ne peut pas prétendre préserver la souveraineté démocratique si les modèles d'intelligence artificielle utilisés par les ministères, les tribunaux, les hôpitaux et les universités d'une nation sont hébergés sur des nuages informatiques extraterritoriaux soumis aux lois d'extraterritorialité de puissances étrangères (comme le **Cloud Act** américain).

Un système d'IA véritablement aligné sur la démocratie exige que le peuple souverain, par l'entremise d'institutions indépendantes et de biens communs certifiés : - contrôle la chaîne logistique du calcul (**compute**) ; - puisse auditer les pondérations mathématiques des modèles de référence ; - participe à la qualification contradictoire des corpus servant à l'entraînement public.

Sans DHITL, le gouvernement par les algorithmes réalise le vieux rêve de la technocratie autoritaire : une administration des choses sans citoyens, où l'humain n'est plus qu'un spectateur impuissant de sa propre déposssession.

4. Les quatre séparations architecturales de DHITL

Pour traduire cette exigence politique en architecture logicielle concrète, la doctrine PrivAI (**La personne numérique mandatée**, §8) impose ****quatre séparations étanches**** au sein de tout flux institutionnel :

1. ****Séparation Proposition / Décision :** Un agent ou un modèle peut analyser, synthétiser, recommander ou classer des options ; il ne transforme jamais de lui-même une proposition en décision exécutoire. La décision demeure un acte de volonté humaine souveraine. 2. ****Séparation Autorisation / Exécution :** Une action valide peut être exécutée à la vitesse de la machine (déclenchement de paiements, mise à jour d'un registre), mais le jeton d'autorisation qui a déclenché l'exécution doit être signé cryptographiquement par une clé humaine nominative et auditable. 3. ****Séparation Exécution / Responsabilité :** Un algorithme d'optimisation peut accomplir la tâche technique sans jamais devenir le répondant légal. En cas de dommage, l'institution ne peut se réfugier derrière

l'outil : la responsabilité remonte sans atténuation vers l'ordonnateur humain. 4.

Séparation Traçabilité des actes / Surveillance des personnes : DHITL exige la traçabilité absolue des actes de puissance publique et des décisions corporatives engageantes, tout en interdisant le flicage biométrique et cognitif permanent des administrés et des travailleurs. On trace le pouvoir, on sanctuarise le citoyen.

5. L'argument de symétrie DABUS : posséder contre gouverner

La nécessité d'exclure les machines du pouvoir décisionnel souverain trouve son ancrage le plus solide dans un précédent juridique international majeur : la jurisprudence **DABUS** (*Device for the Autonomous Bootstrapping of Unified Sentience*).

Entre 2020 et 2024, le promoteur de ce système a tenté de faire enregistrer des brevets d'invention désignant l'algorithme lui-même comme inventeur officiel. La Cour suprême du Royaume-Uni (*Thaler v Comptroller-General of Patents [2023] UKSC 49*), l'Office européen des brevets (OEB) et les tribunaux fédéraux américains ont unanimement rejeté cette prétention : une invention brevetable exige un inventeur humain, seul titulaire possible de droits et devoirs patrimoniaux.

PrivAI dérive de ce précédent un **axiome de symétrie constitutionnelle fondamentale** :

> **Axiome de symétrie de l'autorité :** Si une machine ne peut pas être déclarée inventeur pour détenir un monopole de propriété privée, elle ne peut à aucun titre être déclarée autorité pour exercer une prérogative de puissance publique ou gouverner des humains.

Ce que le capitalisme refuse à l'IA pour préserver l'ordre patrimonial des entreprises, la République doit *a fortiori* le refuser à l'IA pour préserver l'ordre démocratique des citoyens.

6. L'illusion de l'électeur synthétique et la sanctuarisation du Demos

La forme la plus insidieuse de subversion démocratique ne vient pas d'une rébellion brutale des robots, mais de ce que le magazine PrivAI dénonce sous le titre de **« L'illusion de l'électeur synthétique »** :

Sous prétexte de fluidifier la démocratie participative ou de mesurer « l'opinion publique », des cabinets de conseil et des gouvernements technocratiques déploient d'énormes grappes d'agents conversationnels calibrés pour simuler des panels sociologiques de citoyens (*synthetic personas*). Ces agents sont interrogés pour valider des projets de loi, tester des discours électoraux ou justifier des réformes régressives en affirmant que **« 87 % des citoyens synthétiques consultés approuvent cette mesure »**.

Cette dérive constitue un véritable coup d'État cybernétique contre le **demos** : - Elle remplace le peuple réel, contradictoire, souffrant et vivant, par un simulacre mathématique aligné sur les préjugés statistiques de ses concepteurs ; - Elle permet aux détenteurs de supercalculateurs de fabriquer un consentement

artificiel sur mesure à des coûts marginaux nuls ; - Elle détruit l'essence même du suffrage universel, qui repose sur l'égalité stricte : un être humain vivant, une voix.

Le principe Anti-Demos est sans appel : **le corps électoral est une communauté biologique et morale inviolable.** Tout sondage, toute consultation et tout arbitrage politique fondé sur des entités synthétiques doit être frappé d'illégalité républicaine absolue.

PrivAI n°1 Chapitre 10 : L'infrastructure est l'AI Safety

Compute, données, énergie, modèles et dépendances

Chapitre 10 : L'infrastructure est l'AI Safety

1. La matérialité d'acier et de watts

L'idéologie numérique a longtemps propagé l'illusion d'une informatique désincarnée. Les métaphores évanescentes du « cloud », du « cyberspace » ou des « algorithmes virtuels » occultent la réalité physique la plus brutale : l'intelligence artificielle est **une des industries les plus lourdes, les plus centralisées et les plus énergivores de l'histoire humaine**.

L'intelligence artificielle contemporaine, c'est : - des centaines de milliers d'accélérateurs graphiques (GPU, TPU) gravés par une unique fonderie mondiale (TSMC à Taïwan) selon des procédés nanométriques extrêmes ; - des centres de données monumentaux consommant autant d'électricité qu'une agglomération de plusieurs millions d'habitants ; - des millions de mètres cubes d'eau douce évaporés pour refroidir les baies de serveurs ; - des câbles sous-marins transocéaniques contrôlés par les oligopoles de la connectivité mondiale.

Prétendre concevoir une « AI Safety » qui se limiterait à des filtres de conversation éthiques, à des comités de déontologie ou à des déclarations de bonnes pratiques, tout en abandonnant la possession du matériel et de l'énergie à trois ou quatre conglomérats transnationaux, est une hypocrisie politique insoutenable.

La règle d'acier posée par PrivAI est limpide : **l'infrastructure est l'AI Safety**. Qui ne possède pas son calcul ne possède pas sa liberté.

2. Dépasser le modèle du pod : PrivAI et le protocole Solid

Dans l'histoire de la résistance au Web centralisé, le projet **Solid** initié par Tim Berners-Lee a représenté une avancée conceptuelle majeure : rendre à l'utilisateur le contrôle de ses données personnelles en les hébergeant dans des espaces décentralisés (**Personal Online Data Stores** ou **Pods**), la plateforme devant demander l'accès à ces données pour chaque service.

PrivAI salue cet effort pionnier mais constate ses limites face à l'âge des modèles génératifs et agentiques.

| Dimension | Approche Solid (Web décentralisé) | Approche PrivAI (Souveraineté cognitive) | |---|---| | **Objet central** | Les données statiques (fichiers, contacts, profils). | L'agence, les représentations, le calcul et les actes opposables. | | **Lieu d'action** | Où sont stockées les données (Pod personnel). | Qui exécute l'inférence et sous quelle chaîne de mandat. | | **Modèle d'accès** | Autorisation de lecture/écriture via API. | Projection cognitive bornée KYS et non-substitution politique. | | **Imputabilité** | Gestionnaire de clés cryptographiques. | Requis probatoires, traçabilité des actes et chaîne de

responsabilit . |

PrivAI ne se contente pas de sanctuariser le lieu du stockage : il sanctuarise ****le moteur d'inf rence et la cha ne de d cision****. Avoir ses donn es dans un coffre personnel ne prot ge de rien si, pour les analyser ou r pondre   une convocation administrative, on est oblig  de les envoyer dans le mod le propri taire d'un tiers qui les exploitera pour affiner sa domination institutionnelle.

3. Le salut par les mod les ouverts et le calcul local

La ligne de d fense de la souverainet  humaine repose sur le d veloppement vigoureux et non n gociable de ****l' cosyst me open-weights et local-first**** :

1. ****L' mancipation du mod le local : **** L'optimisation algorithmique, la quantification (4-bit, 2-bit) et les progr s des puces grand public permettent d sormais d'ex cuter des mod les de plusieurs dizaines de milliards de param tres sur des ordinateurs individuels ou des serveurs locaux associatifs. 2.

****L'immunit  contre la censure et la coupure : **** Un mod le tournant en local sur une station de travail hors-ligne ne peut  tre ni d sactiv    distance, ni censur  par une mise   jour silencieuse de conditions d'utilisation, ni soumis   une coupure de r seau ordonn e par une puissance  trang re. 3. ****La transparence int grale des poids : **** Seuls les mod les dont les poids sont publics et inspectables permettent de certifier l'absence de portes d rob es, de filtres d'influence id ologique clandestins ou de t l m trie extractive.

La souverainet  cognitive n'est pas un slogan : c'est un poste de calcul personnel, reli    une  nergie ma tris e, ex cutant un mod le inspectable, au service d'un esprit libre.

4. La g opolitique du silicium et la fable des mod les fronti res

La rh torique promotionnelle des laboratoires de pointe impose l'id e que seule une course effr n e vers des architectures g antes (mod les de plus de 500 milliards de param tres entra n s sur des m gagrid d' nergie de plusieurs centaines de m gawatts) permettrait d'atteindre l'intelligence utile.

Cette fable sert un objectif politique pr cis : **** riger une barri re capitaliste insurmontable****. - En maintenant la fronti re de l' tat de l'art   un seuil financier inaccessible aux citoyens, aux universit s et aux petites nations, les conglom rats s'assurent que toute la cognition avanc e de l'humanit  transite obligatoirement par leurs serveurs. - Ce mod le repose sur une vuln rabilit  g opolitique colossale : la d pendance absolue envers les machines de photolithographie extr me UV n erlandaises (ASML) et les usines de fabrication ta wanaises (TSMC), cr ant un goulet d' tranglement mondial sous la tutelle militaire et r glementaire des superpuissances.

PrivAI d nonce cette fuite en avant : la s curit  d mocratique ne consiste pas   courir derri re l'hypertrophie computationnelle des monopoles, mais   concevoir une informatique cognitive r siliente, d centralis e et proportionn e aux besoins

r els de la d lib ration et de l' mancipation.

5. Le seuil capacitaire des mod les 3B-8B et le triomphe de la frugalit 

L'avanc e technologique la plus  mancipatrice de ces derni res ann es n'est pas l'inflation des clusters g ants, mais l' l vation spectaculaire de l'efficacit  des **petits mod les ouverts (de 3   8 milliards de param tres)** :

- Gr ce aux techniques de distillation, de quantification agressive (Q4_K_M, AWQ) et d'entra nement sur des corpus synth tiques hautement filtr s, un mod le de 3B ou 7B param tres en 2026 rivalise, sur les t ches de raisonnement logique, d'analyse documentaire et d'extraction de faits, avec les monstres propri taires d'il y a trois ans. - Ce seuil capacitaire change la donne politique : un mod le 8B quantifi  tient sur 5 Go de m moire vive. Il s'ex cute   plus de 30 jetons par seconde sur le processeur neuronal (*NPU*) d'un ordinateur portable grand public ou sur une puce ARM basse consommation, pour une enveloppe  nerg tique inf rieure   25 watts. - La frugalit  computationnelle brise l'asym trie : le citoyen n'a plus besoin de louer les faveurs d'un supercalculateur  tranger pour auditer ses contrats ou r diger ses recours. Son mat riel personnel suffit   lui conf rer une d fense cognitive de premier rang.

6. F d rations de calcul citoyen et inf rence v rifiable (RAIX)

Pour les op rations complexes exigeant une puissance sup rieure (simulations de politiques publiques, audits crois s de grands jeux de donn es administratifs), la solution PrivAI ne passe pas par la soumission au cloud marchand, mais par la mutualisation coop rative formalis e dans les travaux sur la *Potentique du calcul* (*Potentics of Compute*) et le protocole **RAIX** (*Resource Allocation for Inferred eXecution*) :

1. **La mise en r seau de capacit s dormantes** : Des millions de processeurs graphiques et de stations de travail citoyennes restent inactifs la nuit. Des f d rations d centralis es permettent d'agr ger ce calcul b n vole ou r tribu  en biens communs, sous le contr le exclusif de collectifs ind pendants. 2.

L'inf rence v rifiable sans confiance aveugle : Le protocole RAIX r sout l'inconv nient historique des r seaux distribu s par l'introduction de preuves d'inf rence cryptographiques et d'audits statistiques crois s. L'administr  qui soumet un calcul confidentiel re oit un requ  d'ex cution math matique certifiant que le code exact a  t  ex cut  sur les donn es exactes, sans fuite d'information ni falsification du r sultat. 3. **Le d couplage infrastructurel** :

L'intelligence collective s'affranchit des d pendances captives. Le r seau citoyen devient lui-m me un ordinateur apprenant souverain, immunis  contre les censures d' tat et les chantages tarifaires des plateformes.

PrivAI n°1 Chapitre 11 : Des individus capables ensemble

Articulation avec les communs cognitifs sans capture collective

Chapitre 11 : Des individus capables ensemble

1. Le piège du collectivisme cognitif

Face à la toute-puissance des oligopoles de l'IA, une réponse spontanée consiste à invoquer les vertus exclusives du « collectif » ou de « l'intérêt général ». Il suffirait, affirme-t-on, de nationaliser les modèles ou de créer de grands consortiums publics pour réconcilier l'intelligence artificielle avec le peuple.

L'histoire politique et l'analyse de sécurité démocratique incitent à une méfiance absolue envers cette fausse solution.

Un commun mal gouverné ou une structure étatique centralisée peuvent se révéler tout aussi prédateurs pour la liberté humaine qu'une corporation privée. C'est le cas de l'« Objection 7 » soulevée dans « Democratic AI Safety » :

> « Le risque de capture du commun : Un bien commun cognitif peut être capturé de l'intérieur par une oligarchie bureaucratique, dévoyé par des intérêts corporatistes subventionnés, ou absorbé par un appareil d'État répressif pour imposer une vérité officielle et traquer les dissidents.

La souveraineté collective ne saurait être un substitut magique à la souveraineté personnelle : « un groupe d'individus dominés et asservis ne forme pas une communauté libre ; il forme un troupeau manipulable. »

Pour que les communs soient authentiquement émancipateurs, ils doivent reposer sur des personnes physiques elles-mêmes outillées, capables de dissidence, d'audit contradictoire et de sécession si l'institution dérive.

2. Le principe confédéral : « Renforcer, ne pas cloner »

Pour articuler l'autonomie absolue de la personne et la puissance d'action collective, l'architecture des Livres Vivants et de PrivAI applique une règle constitutionnelle stricte : « la confédération sans subordination ».

Dans cette approche : - « L'individu conserve son ancre : Ses écrits, ses preuves, ses profils KYS et ses jumeaux lui appartiennent en propre. Nulle plateforme, nulle association ne peut s'en proclamer propriétaire. - La mise en commun se fait par renforcement : On ne fusionne pas les consciences ni les bases de données dans un lac géant anonyme ; on tisse des liens hypertexte traçables et des contrats de projection partagés (« Renforcer, ne pas cloner »). -

« L'infrastructure commune reste neutre : Des structures de soutien comme l'association C.O.R.S.I.C.A. ou l'Institut Mariani peuvent mettre à disposition des serveurs d'inférence, des hébergements statiques ou des espaces de débat public, mais elles n'interviennent jamais comme censeurs éditoriaux ni comme représentants juridiques obligés des auteurs.

Chaque Livre Vivant, chaque citoyen outillØ reste le maître souverain de sa parole et de ses engagements.

3. L'alliance fØconde : PrivAI et Cogentia Commons

Cette dialectique trouve son incarnation technique dans la complØmentaritØ entre ****PrivAI**** et ****Cogentia Commons**** :

“text SOUVERAINETÉCOGNITIVE INTÉGRALE

4	4	PrivAI	Cogentia Commons
- Jumeau personnel	- MØmoire partagØe	- Profils bornØs	-
DØlibØration DHITL	- Secret lØgitime	- Savoirs vØrifiØs	- Bouclier cognitif
- Preuves publiques	(Le for intØrieur (L'agora dØmocratique et la dØfense) et la coopØration) “		

1. ****PrivAI** est le bouclier privØ : ****** Il protØge le citoyen contre l'intrusion, garantit la confidentialitØ de ses raisonnements intimes, gØre ses dØlØgations d'actes et lui permet de se dØfendre àarmes Øgales face aux machines des personnes morales. 2. ****Cogentia Commons** est l'espace public : ****** Il mutualise les enquØtes citoyennes, documente les dØrives institutionnelles, confronte les thØories àl'Øpreuve des faits (Seconde MØthode) et bâit des corpus de rØfØrence opposables au pouvoir.

L'individu capable et la communautØ solidaire cessent de s'opposer : le premier nourrit le second de ses dØcouvertes libres ; le second protØge le premier en garantissant l'accØs àune vØritØ partagØe et vØrifiable.

4. La fraternitØ effective comme non-abandon capacitaire sans capture

Dans le triptyque rØpublicain revisitØ par la doctrine de l'Autonomie de CapacitØ (*Rendre capable*, §4), la fraternitØ cesse d'Øtre une pØtition morale sentimentale ou un alibi pour l'assistanat clientØliste. Elle est redØfinie comme un impØratif d'action matØrielle :

> ****La FraternitØ effective : **** Le devoir constitutionnel et collectif de ****non-abandon capacitaire sans capture relationnelle****.

Face au choc de l'automatisation institutionnelle, laisser un citoyen dØmuni, sans compØtences ou sans Øquipement cognitif pour affronter l'administration numØrique constitue une forme moderne de violence d'État. La fraternitØ effective impose :

1. ****L'Øquipement capacitaire garanti : **** La collectivitØ doit assurer àchaque personne, quels que soient son âge, son statut ou ses moyens financiers, l'accØs à un environnement de calcul local souverain et àune formation critique aux outils d'investigation. 2. ****Le refus du paternalisme algorithmique : **** Aider une personne ne signifie pas penser àsa place ni la soumettre àun tuteur numØrique bienveillant qui filtre ce qu'elle a le droit de lire ou d'Øcrire. L'aide capacitaire doit renforcer l'autonomie de dØcision de l'individu, jamais la remplacer par une dØpendance docile. 3. ****Le secours probatoire mutuel : **** Lorsqu'un individu vulnØrable est broyØ par une injustice algorithmique (comme les

victimes de Robodebt ou du profilage CAF), la fraternité civique organise la mutualisation immédiate de l'expertise juridique et des contre-traces pour briser l'isolement du requérant.

5. La coopération stigmergique par les traces

Comment des milliers de citoyens souverains et d'organisations autonomes peuvent-ils coordonner leurs efforts sans créer un appareil bureaucratique centralisé et pesant ?

La réponse réside dans la **coopération stigmergique** (*Stigmergie sans limite haute*), empruntée aux systèmes vivants décentralisés : - Dans une termitière, aucun chef d'orchestre ne commande aux ouvrières : chaque individu agit en modifiant son environnement matériel, et la trace de son travail (*la phéromone*) guide l'action du suivant. - Dans l'écosystème PrivAI / Cogentia, les enquêteurs, juristes, codeurs et citoyens agissent en déposant des traces qualifiées dans le corpus ouvert : un précédent juridique documenté, une faille d'algorithme public signalée, un script de vérification d'inférence publié sous licence libre. - D'autres agents et humains s'emparent de ces traces pour bâtir des recours collectifs, affiner les modèles frugaux ou alerter la presse.

La coordination s'opère par la richesse et l'exactitude des traces partagées, non par la soumission à une chaîne de commandement hiérarchique.

6. Le pacte anti-capture et le droit de sécession cognitive

Tout regroupement humain et tout bien commun court le risque permanent d'être détourné de sa mission originelle par des groupes d'intérêt ou des bureaucraties professionnelles (loi d'airain de l'oligarchie de Robert Michels).

Pour prémunir durablement les coopératives cognitives contre ce péril, PrivAI intègre un **pacte anti-capture** reposant sur le **droit de sécession cognitive inconditionnel** : 1. **Zero enfermement propriétaire** : Tout le code, tous les formats de métadonnées et tous les corpus méthodologiques d'un commun doivent être publiés sous licences réputées libres et virales (ex. CC BY-SA 4.0, AGPLv3). 2.

Le droit de fork intégral : Si la gouvernance d'une fondation de calcul ou d'une association civique commence à censurer des membres, à transiger avec des monopoles industriels ou à privatiser des connaissances, toute minorité dissidente a le droit technique et juridique instantané de cloner l'intégralité du corpus, des traces publiques et des outils pour poursuivre l'œuvre sous une autre bannière. 3. **L'intégrité des ancres personnelles** : La sécession collective n'affecte en rien les jumeaux privés des participants, qui demeurent hébergés sur leurs postes personnels indépendants.

Le commun n'est pas une prison dorée : c'est un foyer ouvert de pairs libres, qui ne tient que par la confiance mutuelle et l'utilité réelle qu'il apporte à chacun de ses membres.

PrivAI n°1 Chapitre 12 : PrivAI comme Reality Test

Mesurer les capacités réellement rendues à la personne

Chapitre 12 : PrivAI comme Reality Test

1. Le refus de la prophétie sans preuve

Les discours sur l'intelligence artificielle souffrent d'une inflation rhétorique dévastatrice. Entre le messianisme des industriels de la Silicon Valley promettant l'émancipation totale de l'humanité et le catastrophisme spectaculaire des théoriciens de l'alignement annonçant l'extinction imminente de l'espèce, les citoyens sont pris en otage entre deux formes de sidération passive.

PrivAI refuse expressément ces facilités discursives. Fidèle aux préceptes de la Seconde Méthode instituée par Jean Hugues Robert, le projet n'entend être jugé ni sur ses déclarations d'intention, ni sur son élégance typographique, ni sur la subtilité de ses concepts juridiques.

Il n'entend être jugé que sur son **contact brutal et mesurable avec le Réel**.

La question directrice qui gouverne l'ensemble de cette entreprise intellectuelle et technologique est d'une simplicité tranchante :

> **« Après intervention de PrivAI, la personne physique dispose-t-elle RÉELLEMENT de davantage de capacité autonome, vérifiable et révocable qu'avant ? »**

Si la réponse est négative si l'utilisateur d'un jumeau ou le lecteur de ce Livre Vivant reste aussi démuné, aussi manipulable et aussi dépendant des serveurs des oligopoles qu'auparavant, alors PrivAI aura échoué, n'étant qu'un bavardage philosophique de plus.

Si la réponse est affirmative, alors nous aurons tracé une brèche concrète dans le mur de la domination institutionnelle.

2. Le Capable Test appliqué à l'IA : de l'illusion formelle à l'exercabilité réelle

Pour transformer cette exigence en protocole d'audit rigoureux, PrivAI applique le cadre d'évaluation du [Capable Test](file:///C:/tweesic/barons-Mariani/projects/capable/capable-test.md) (issu des travaux sur le [Principe d'effectivité](file:///C:/tweesic/barons-Mariani/research/principe_effectivite.md)) :

> **« Une règle ou un outil ne vaut que par ses effets réels sur la capacité d'agir. »**

L'analyse distingue trois seuils fondamentaux : 1. **L'ouverture d'un possible** : Déclarer abstraitement un « droit d'accès aux données » ou une « portabilité » dans une loi ne crée aucune liberté réelle tant que l'infrastructure technique n'est pas construite. 2. **L'accessibilité matérielle** : Le citoyen moyen sait-il que le contre-pouvoir existe ? Peut-il en comprendre l'interface sans posséder un

doctorat en cryptographie ou des moyens financiers prohibitifs ? 3.

****L'exercabilité effective (*le test de contrariété) :**** Que se passe-t-il lorsque le système est soumis à une véritable épreuve de force adverse ? Lorsque l'administration fiscale refuse de communiquer les logs de son modèle de ciblage, ou lorsqu'une banque bloque un compte sur une alerte algorithmique, l'individu peut-il effectivement forcer la réouverture contradictoire de la décision et faire condamner l'abus de pouvoir ?

Un système technique ou juridique qui échoue au test de contrariété est un hochet managérial. PrivAI ne conçoit que des mécanismes bâtis pour résister au contentieux réel.

3. La matrice des sept Reality Cases de PrivAI n°1

Ce premier numéro de PrivAI ancre sa légitimité dans ****sept épreuves empiriques documentées****, issues de conflits majeurs entre personnes physiques et bureaucraties augmentées :

| Reality Case | Terrain d'affrontement réel | Pathologie institutionnelle mise au jour | Contre-pouvoir effectif PrivAI valide | ---|---|---| | ****[Case 01](file:///C:/tweesic/barons-Mariani/projects/privai/cases/case-01-migration-tested-twin.md)**** | Portabilité et changement d'opérateur d'IA | Verrouillage propriétaire (*vendor lock-in*) et capture des données personnelles. | ****Garantie Migration-Tested v0.1**** : extraction à froid, restauration *air-gap* sur modèles ouverts en moins de 60 min. | | ****[Case 02](file:///C:/tweesic/barons-Mariani/projects/privai/cases/case-02-datajust-opacite-administrative.md)**** | Barémisation algorithmique de la justice (France) | Tentative d'automatisation de l'indemnisation corporelle sous opacité méthodologique. | ****Abandon du projet suite aux recours**** : exigence constitutionnelle d'auditabilité publique des jeux de données d'entraînement. | | ****[Case 03](file:///C:/tweesic/barons-Mariani/projects/privai/cases/case-03-traceabilite-dilution-decisionnelle.md)**** | Décisions managériales et bancaires automatisées | Les 4 alibis de dilution : *l'institution*, *le processus*, *le système*, *le modèle*. | ****Chaîne minimale d'imputation**** : nullité de plein droit de tout acte sans mandat humain nominatif et journal de bord opposable. | | ****[Case 04](file:///C:/tweesic/barons-Mariani/projects/privai/cases/case-04-kys-profilage-cognitif-borne.md)**** | Profilage psychométrique des plateformes marchandes | Capture universelle, flicage comportemental et consentement extorqué sous contrainte. | ****Protocole KYS**** : projection cognitive bornée par finalité stricte, révocabilité matérielle instantanée et non-auto-évaluation. | | ****[Case 05](file:///C:/tweesic/barons-Mariani/projects/privai/cases/case-05-parcoursup-et-la-boite-noire-decisionnelle.md)**** | Affectation universitaire des bacheliers (France) | Décision 2020-834 QPC : sanctuarisation du « secret des délibérations » contre l'explicabilité locale. | ****Écologie probatoire citoyenne**** : contre-simulations ouvertes, traçabilité des refus et recours pour rupture d'égalité républicaine. | | ****[Case 06](file:///C:/tweesic/barons-Mariani/projects/privai/cases/case-06-horizon-presomption-fiabilite-machine.md)**** | Scandale *Post Office Horizon* (Royaume-Uni) | Présomption d'infailibilité machine (*PACE 1984 s.69*) conduisant à 900 condamnations pénales injustes. | ****Renversement de la charge de la preuve**** : présomption d'erreur matérielle et production d'alibis non-machine hors-système. | | ****[Case**

07](file:///C:/tweesic/barons-Mariani/projects/privai/cases/case-07-robodebt-automatisation-du-soupcon.md)**
| Scandale *Robodebt* (Australie, 2016-2023) | Moyennisation statistique illégale
des revenus et extorsion unilatérale de 1,73 Md\$ de fausses dettes. | **Principe
d'indivisibilité de la faute humaine** : interdiction du soupçon automatique et
responsabilité personnelle directe des ordonnateurs. |

Ces sept cas ne constituent pas des spéculations prospectives : ce sont les
cicatrices bien réelles de milliers de vies broyées par l'impunité des automates
institutionnels. Ils définissent le cahier des charges impératif de notre sécurité
démocratique.

4. Conclusion du numéro 1 : L'appel au contre-pouvoir cognitif

À la question inaugurale de ce premier numéro :

> **« Qui restera souverain à l'âge des personnes morales augmentées par l'IA ?
»**

La réponse dépend désormais de notre volonté collective et individuelle.

Si nous persistons dans la naïveté des chartes d'éthique sans contrainte, si nous
nous contentons de supplier les géants du calcul de « bien se comporter », si nous
acceptons de déléguer la justice, l'enseignement, la médecine et le vote à des
boîtes noires statistiques dont les maîtres sont invisibles, alors la souveraineté
humaine aura vécu. Nous serons les serfs consentants d'un féodalisme cybernétique.

Mais une autre voie est ouverte.

Elle commence par le refus de l'alibi algorithmique. Elle passe par
l'appropriation méthodique de nos propres infrastructures de calcul, de nos
modèles ouverts et de nos chaînes de preuve locales. Elle s'accomplit dans
l'alliance lucide d'individus capables, solidaires au sein de communs
démocratiques inaliénables.

**La machine n'est pas le maître. L'institution n'est pas un dieu. L'humain reste
le seul sujet de droit, de souffrance, de parole et d'espérance.**

Ce premier numéro de PrivAI n'est pas un monument figé dans le marbre : c'est un

Livre Vivant en travail permanent ('frozen: false', 'status: working'). Il
continuera de s'enrichir au gré des luttes judiciaires, des avancées du calcul
frugal et des contributions du peuple souverain.

C'est à cette souveraineté conquise et défendue pied à pied que cette Suvre est
dédiée.